

Uvod v podatkovno znanost

Luka Vranješ & Blaž Pridgar

Kdo sva?



Luka Vranješ
Data Science Lead & Co-founder @ Valira AI



Blaž Pridgar
Data Scientist @ Valira AI

Pregled

- Cilj usposabljanja:

  “Od surovih poslovnih podatkov do delujočega modela strojnega učenja v praksi.”

- Potek celotnega programa (5 sklopov):
  1. Uvod v podatkovno znanost (spoznavanje podatkov, statistika, vizualizacija) ← Danes
  2. Eksplorativna analiza in priprava podatkov (čiščenje, inženiring značilk) ← Danes
  3. Uvod v strojno učenje (koncepti učenja, validacija, metrike)
  4. Nadzorovano učenje v praksi (regresija, klasifikacija, drevesni modeli)
  5. Nenadzorovano učenje v praksi (gručenje, zmanjšanje dimenzionalnosti, pot v produkcijo)
  6. Produkcionalizacija

Plan za danes

- Uvod v podatkovno znanost
  - Kaj je podatkovna znanost?,
  - Python ekosistem,
  - Opisne statistike,
  - Vizualizacija podatkov.
- Eksplorativna analiza in priprava podatkov
  - Obravnava manjkajočih vrednosti
  - Detekcija in obravnava osamelcev
  - Normalizacija in standardizacija
  - Oblikovanje značilk

Način dela

- Kratki teoretični bloki (približno 1h) + prikaz v živo
- Po koncu vsakega bloka: “samostojno” delo v Pythonu (Jupyter) na dveh primerih (Telekom & Spletna trgovina).



Kaj je podatkovna znanost?

Od poslovnega problema do podatkov

Kaj lahko naredimo s podatki?

- Podatki nam pomagajo:
  - **Razumeti poslovanje**: Katere kategorije izdelkov kupci pogosto kupujejo skupaj?
  - **Napovedovati izide**: Koliko naročil lahko pričakujemo prihodnji teden?
  - **Podpreti odločitve**: Za katere izdelke moramo pravočasno dopolniti zalogo?

Podatki → Informacije → Odločitev → Ukrep

Kaj je podatkovna znanost

- “Pridobivanje znanj iz podatkov za reševanje konkretnih problemov”
- Tok projekta:
  1. Opredelimo vprašanje.
  2. Pridobimo in povežemo podatke.
  3. Preverimo kakovost in raziščemo vzorce.
  4. Izvedemo analizo ali zgradimo model.
  5. Ovrednotimo in predstavimo rezultate.
  6. Rezultate uporabimo v praksi.

- Rezultat je lahko:
  - Ugotovitev ali priporočilo.
  - Poročilo oziroma vizualizacija.
  - Napovedni model ali segmentacija.

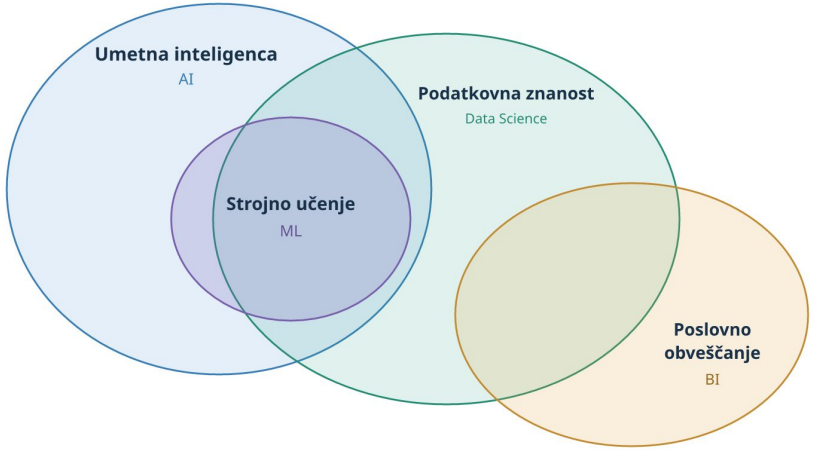
Programiranje + statistika + domensko znanje

- Podatkovna znanost povezuje tri vrste znanja:

PODROČJE	KAJ PRISPEVA
Programiranje	Pridobivanje, povezovanje in obdelavo podatkov; avtomatizacijo
Statistika in matematika	Razumevanje variabilnosti, vzorcev in negotovosti
Domensko znanje	Prava vprašanja, pomen podatkov in uporabnost rezultatov

AI, strojno učenje, podatkovna znanost in BI

- **Umetna inteligenca (AI)** -> Široko področje sistemov za naloge, kot so prepoznavanje, razumevanje jezika, sklepanje in načrtovanje.
- **Strojno učenje (ML)** -> Podpodročje AI, pri katerem se modeli učijo vzorcev iz podatkov.
- **Podatkovna znanost (Data Science)** -> Povezuje metode za pridobivanje znanja iz podatkov; pri tem lahko uporablja ML/AI.
- **Poslovno obveščanje in analitika (BI)** -> Podpirata spremljanje kazalnikov, poročanje in raziskovanje poslovanja.



Vloga Analitike

- **Opisna analitika** – Kaj se je zgodilo?
  - S kazalniki, agregacijami in vizualizacijami povzamemo dogajanje.
  - Primer: Kako se je prodaja spletne trgovine spreminjala po mesecih?
- **Diagnostična analitika** – Zakaj se je zgodilo?
  - S primerjavami in preverjanjem hipotez raziskujemo možne razloge.
  - Primer: Je upad prodaje povezan z manj obiska, nižjo konverzijo ali pomanjkanjem zaloge?
- **Napovedna analitika** – Kaj se bo verjetno zgodilo?
  - S statističnimi modeli in strojnim učenjem napovedujemo prihodnje izide.
  - Primer: Kakšno prodajo pričakujemo prihodnji mesec?
- **Predpisovalna analitika** – Kaj naj naredimo?
  - Z optimizacijo, simulacijami in poslovnimi pravili predlagamo ukrepe glede na cilje in omejitve.
  - Primer: Koliko izdelkov naj naročimo ob omejenem proračunu in skladiščnem prostoru?

Kje so ChatGPT in generativna AI?

- Umetna inteligenca ni samo generiranje besedila:
  - **Napovedovanje**: Verjetnost odhoda naročnika.
  - **Prepoznavanje**: Zaznavanje napake na fotografiji izdelka.
  - **Segmentacija**: Skupine kupcev s podobnimi navadami.
  - **Generiranje**: Priprava besedila, slike ali programske kode.

- Na tem usposabljanju se osredotočamo na:
  - Tabelarične podatke.
  - Raziskovanje in pripravo podatkov.
  - Napovedovanje in gručenje s strojnim učenjem.

Klasično programiranje in strojno učenje

Klasično programiranje

- Podatki + napisana pravila -> rezultat
- Primer pravila:
  - “Če naročnik nima vezave in je trikrat kontaktiral podporo, ga uvrsti na seznam za stik.”

Nadzorovano strojno učenje

- Zgodovinski podatki + znani izidi -> naučen model
- Novi podatki + naučen model -> napoved
  - Model išče vzorce, ki naj bi bili uporabni tudi na novih podatkih.

Kdaj potrebujemo ML — in kdaj ne?

- Koliko naročnikov je odšlo prejšnji mesec? -> SQL, agregacija, poročilo
- Opozori na račun, ki zamuja več kot 30 dni. -> Poslovno pravilo
- Kdo bo verjetno odšel naslednji mesec? -> Napovedni model
- Kateri kupci imajo podobne nakupne navade? -> Gručenje

- ML je smiseln, kadar:
  - Je pravila težko določiti ročno.
  - Imamo ustrezne podatke za učenje.
  - Lahko kakovost rezultata preverimo.
  - Rezultat podpira dejansko uporabo ali odločitev.

- Večja kompleksnost sama po sebi ne pomeni boljše rešitve.

Kako podatke predstavimo modelu?

ID	TRAJANJE RAZMERJA (MESECI)	MESEČNI RAČUN (EUR)	VRSTA VEZAVE	ODŠEL V 30 DNEH
A	6	45	Brez	Da
B	36	62	Dve leti	Ne
C	14	38	Eno leto	Ne

- **Opazovanje**: Ena vrstica – tukaj naročnik na izbrani datum.
- **Značilke** oziroma X: Podatki, iz katerih napovedujemo.
- **Ciljna spremenljivka** oziroma y: Izid, ki ga napovedujemo.
- **Identifikator**: Podatek, ki pove, komu vrstica pripada.

Kako podatke predstavimo modelu?

ID	TRAJANJE RAZMERJA (MESECI)	MESEČNI RAČUN (EUR)	VRSTA VEZAVE	ODŠEL V 30 DNEH
A	6	45	Brez	Da
B	36	62	Dve leti	Ne
C	14	38	Eno leto	Ne

- **Opazovanje**: Ena vrstica – tukaj naročnik na izbrani datum.
- **Značilke** oziroma X: Podatki, iz katerih napovedujemo.
- **Ciljna spremenljivka** oziroma y: Izid, ki ga napovedujemo.
- **Identifikator**: Podatek, ki pove, komu vrstica pripada.

Kako podatke predstavimo modelu?

ID	TRAJANJE RAZMERJA (MESECI)	MESEČNI RAČUN (EUR)	VRSTA VEZAVE	ODŠEL V 30 DNEH
A	6	45	Brez	Da
B	36	62	Dve leti	Ne
C	14	38	Eno leto	Ne

- **Opazovanje**: Ena vrstica — tukaj naročnik na izbrani datum.
- **Značilke** oziroma X: Podatki, iz katerih napovedujemo.
- **Ciljna spremenljivka** oziroma y: Izid, ki ga napovedujemo.
- **Identifikator**: Podatek, ki pove, komu vrstica pripada.

Kaj pomeni, da imamo dobre podatke?

- **Ustreznost** -> Ali podatki pomagajo odgovoriti na naše vprašanje?
- **Kakovost** -> Ali so pravilni, dovolj popolni in dosledni?
- **Reprezentativnost** -> Ali zajemajo ljudi oziroma primere, za katere bomo rešitev uporabljali?
- **Časovna ustreznost** -> Ali so aktualni in dostopni takrat, ko jih potrebujemo?
- **Dovoljena uporaba** -> Ali jih smemo uporabiti za ta namen?

- Primer:
  - Podatki samo o kupcih, ki so izkoristili kupon, ne predstavljajo nujno vseh kupcev.
  - Model ne more nadomestiti manjkajočega ali izkrivljenega pogleda na poslovanje.

Kako poteka podatkovni projekt?

1. **Razumevanje poslovnega problema -> Sklop 1 (Danes)**
   - Kaj želimo izboljšati?
2. **Razumevanje podatkov -> Sklop 1 (Danes)**
   - Kaj imamo in kaj nam podatki povedo?
3. **Priprava podatkov -> Sklop 2 (Danes)**
   - Kako jih uredimo za analizo in modeliranje?
4. **Modeliranje -> Sklop 3-5**
   - Kateri pristop uporabimo?
5. **Evalvacija -> SKlop 3-5**
   - Ali rezultat ustrezno rešuje problem?
6. **Uporaba in spremljanje -> Sklop 6**
   - Kako rešitev vključimo v delo in preverjamo njeno delovanje?

Kdaj je projekt uspešen?

- **Analitični** oziroma modelni **uspeh**
  - Ugotovitve so zanesljive in uporabne.
  - Napovedi delujejo tudi na novih podatkih.
  - Rezultat primerjamo s preprostim izhodiščem.
- **Poslovni uspeh**
  - Rezultat lahko vključimo v delovni proces.
  - Na njegovi podlagi izvedemo smiseln ukrep.
  - Koristi upravičijo stroške in tveganja.

- Prepoznati ogroženega naročnika ≠ preprečiti njegov odhod.
- Vnaprej določimo, kako bomo merili uspeh.

Spoznajmo podatke





Python ekosistem

spoznavanje s surovimi podatki

Zakaj Python?

- **Standard v podatkovni znanosti:** največ knjižnic, primerov in pomoči na spletu.
- **Brezplačen in odprtokoden:** brez licenc; deluje na Windows, macOS in Linux.
- **Berljiv:** koda je blizu govorjenemu jeziku, zato se ga hitro naučimo.
- **Od analize do produkcije:** isti jezik za raziskovanje, modele in povezavo z drugimi sistemi.
- **Ne nadomešča vsega:**
  - SQL za pridobivanje podatkov iz baz.
  - Excel in Power BI za poročanje.
  - Python ju dopolnjuje, ko analiza preraste preglednico.

Python sklad za delo s podatki

- Vsaka knjižnica pokrije svoj del poti od podatkov do modela:

ORODJE	ZA KAJ GA UPORABIMO
Jupyter Notebook / Lab	Raziskovanje: koda, rezultat in razlaga v enem dokumentu
NumPy	Hitro računanje nad tabelami števil (vektorji, matrike)
Pandas	Delo s tabelami: nalaganje, filtriranje, združevanje, čiščenje
Matplotlib & plotnine	Matplotlib & plotnineVizualizacija: plotnine sestavi graf iz plasti (kot ggplot2 v R)
scikit-learn	Klasično strojno učenje: priprava podatkov, modeli, evalvacija

Python sklad za delo s podatki

- Vsaka knjižnica pokrije svoj del poti od podatkov do modela:



Jupyter: laboratorij, ne tovarna

- **Celica = korak:** kodo izvajamo po delih in takoj vidimo rezultat.
- **Koda + graf + razlaga** v enem dokumentu ⟶ odlično za raziskovanje in predstavitev ugotovitev.
- **Pasti:**
  - Celice lahko poganjamo v poljubnem vrstnem redu ⟶ skrito stanje.
  - Težje verzioniranje, testiranje in avtomatizacija.
- **Za produkcijo:** kodo preselimo v skripte in module ter jo avtomatiziramo.
- **Nasvet:** preden zvezek delite, izberite **Restart & Run All.**



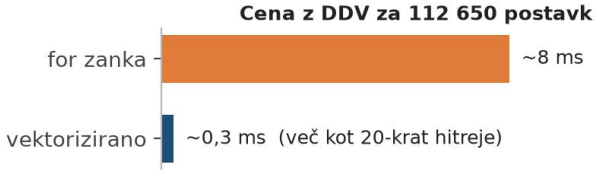
Zvezek beremo od zgoraj navzdol, Python pa si zapomni vrstni red zagona.

Celica [3] je tekla za izpisom, zato izpis ne ustreza kodi nad njim.

NumPy & Pandas: zakaj ne for zanke?

- **DataFrame** = tabela: vrstica je opazovanje, stolpec je spremenljivka.
- **Vektorizacija:** operacijo zapišemo za cel stolpec naenkrat; izvede se v optimizirani kodi.
- **Primer:** cena z DDV za 112 650 postavk spletne trgovine
- `for` zanka čez vse postavke: ~8 ms
- `postavke["price"] * 1.22`: ~0,3 ms → več kot 20× hitreje
- Pri milijonih vrstic to pomeni sekunde namesto minut.
- Vektorizirana koda je tudi **krajša in berljivejša.**





Izmerjeno v zvezku A_prvi_stik_s_podatki; čas je odvisen od računalnika.

Tipi podatkov po obliki

- **Strukturirani:** tabele z vnaprej določenimi stolpci.
  - SQL tabele, CSV, Excel — seznam naročnikov, postavke naročil.
- **Pol-strukturirani:** zapisi imajo strukturo, a ni nujno enaka za vse.
  - JSON logi klicev, dogodki na spletni strani (ogled, košarica, nakup).
- **Nestrukturirani:** brez vnaprej določene strukture.
  - Besedilo reklamacij, posnetki klicev, slike izdelkov.
- Večina poslovnih podatkov ni strukturiranih — klasično strojno učenje pa potrebuje **tabelo.**

Strukturirani

vnaprej določeni stolpci

id	regija	prihodek
1001	LA	23,99
1002	NY	57,49
1003	NY	16,99
1004	DC	38,00

Pol-strukturirani

struktura, a ni enaka za vse

```
{"id": 1001, "tip": "klic",
 "podrobnosti": {
    "trajanje_s": 125}}

{"id": 1002, "tip": "sms",
 "podrobnosti": {
    "dolzina": 42}}
```

Nestrukturirani

brez vnaprej določene strukture

»Paket je prišel z zamudo in poškodovan. Prosim za vračilo denarja.«



slika



posnetek klica

Od ne/pol-strukturiranih podatkov do tabele

- **JSON dogodki → tabela:** polja razgrnemo v stolpce; manjkajoča polja postanejo NaN.
- **Dogodki → povzetek na stranko:** število klicev na podporo v zadnjem mesecu, povprečno trajanje klica.
- **Besedilo → značilke:** dolžina, ključne besede, kategorija pritožbe, sentiment.
- **Zvok → besedilo → značilke:** najprej prepis klica, nato kot zgoraj.
- **Slika → značilke:** kategorija izdelka, zaznana poškodba (da/ne).
- Cilj: **ena vrstica = eno opazovanje** (stranka, naročilo, …), en stolpec = ena lastnost.

```
{"id_stranke": 1001, "tip": "klic",
 "podrobnosti": {"trajanje_s": 125,
                 "smer": "odhodni"}}
{"id_stranke": 1001, "tip": "sms",
 "podrobnosti": {"dolzina_znakov": 42}}
{"id_stranke": 1002, "tip": "klic",
 "podrobnosti": {"trajanje_s": 610,
   "smer": "dohodni", "gostovanje": true}}
```

pd.json_normalize →

id_stranke	tip	trajanje_s	smer	dolzina_znakov	gostovanje
1001	klic	125	odhodni	**NaN**	**NaN**
1001	sms	**NaN**	**NaN**	42	**NaN**
1002	klic	610	dohodni	**NaN**	True

Kjer polja ni, dobimo NaN (oranžno).

Primer iz zvezka A_prvi_stik_s_podatki; stolpci podrobnosti.* so skrajšani.

Tipi podatkov po pomenu

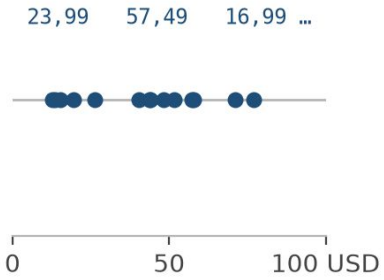
- Tip po pomenu določa, katero statistiko in kateri graf lahko uporabimo:

TIP	PODTIP	PRIMER (TELEKOM / TRGOVINA)
Numerični	Zvezni	Mesečni prihodek, cena izdelka
Numerični	Diskretni	Število telefonov, meseci naročnine
Kategorični	Nominalni	Regija, način plačila
Kategorični	Ordinalni	Dohodkovni razred 1–9, ocena 1–5
Časovni	Datum in čas	Datum nakupa, datum dostave
Tekst / ID	—	Komentar kupca, ID stranke

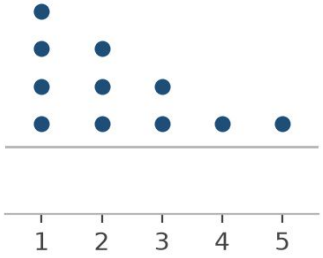
Tipi podatkov po pomenu

- Tip po pomenu določa, katero statistiko in kateri graf lahko uporabimo:

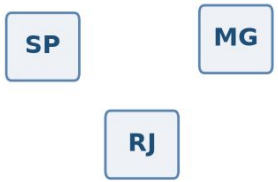
Numerični zvezni
mesečni prihodek: poljubna vrednost



Numerični diskretni
število telefonov: samo cela števila

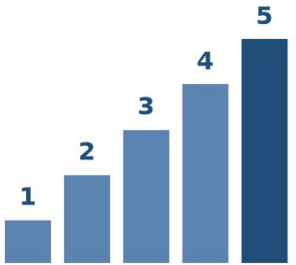


Kategorični nominalni
zvezna država, način plačila



vrstni red nima pomena

Kategorični ordinalni
ocena kupca 1–5



1 < 2 < 3 < 4 < 5, razmiki niso nujno enaki

Shematski prikaz na umetnih podatkih.

Hands-on 1: prvi stik s podatki

- `pd.read_csv()` – naložimo tabelo
- `.shape` – koliko vrstic in stolpcev
- `.head()` – prvih nekaj vrstic
- `.info()` / `.dtypes` – tipi stolpcev in število ne-manjkajočih vrednosti
- **Kje se je Pandas zmotil?**
  - Datum kot besedilo (`object` / `str`)
  - Poštna številka kot število (izgubljena vodilna ničla)
  - Celo število kot `float` (ker nekaj vrednosti manjka)
- Zvezek `B_prvi_stik_s_podatki`



Opisne statistike

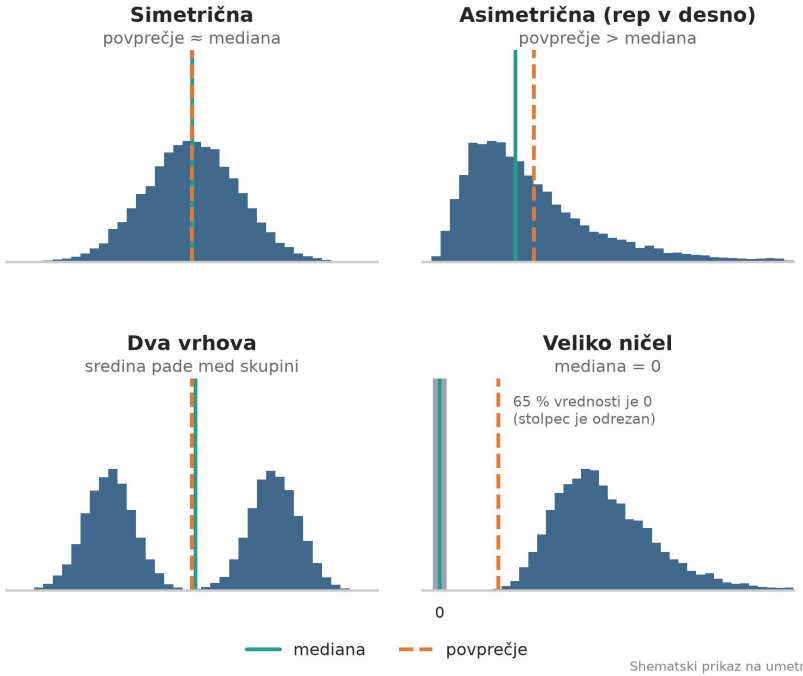
Kaj nam številke povedo o podatkih?

Kaj nam povedo opisne statistike

- Pred modelom moramo vedeti, kaj je v podatkih.
- Za vsak stolpec tri vprašanja: kakšne oblike je porazdelitev, kje je sredina, kako razpršene so vrednosti.
- Odgovor določa, kako bomo stolpec čistili in jih transformirali.

Oblika porazdelitve

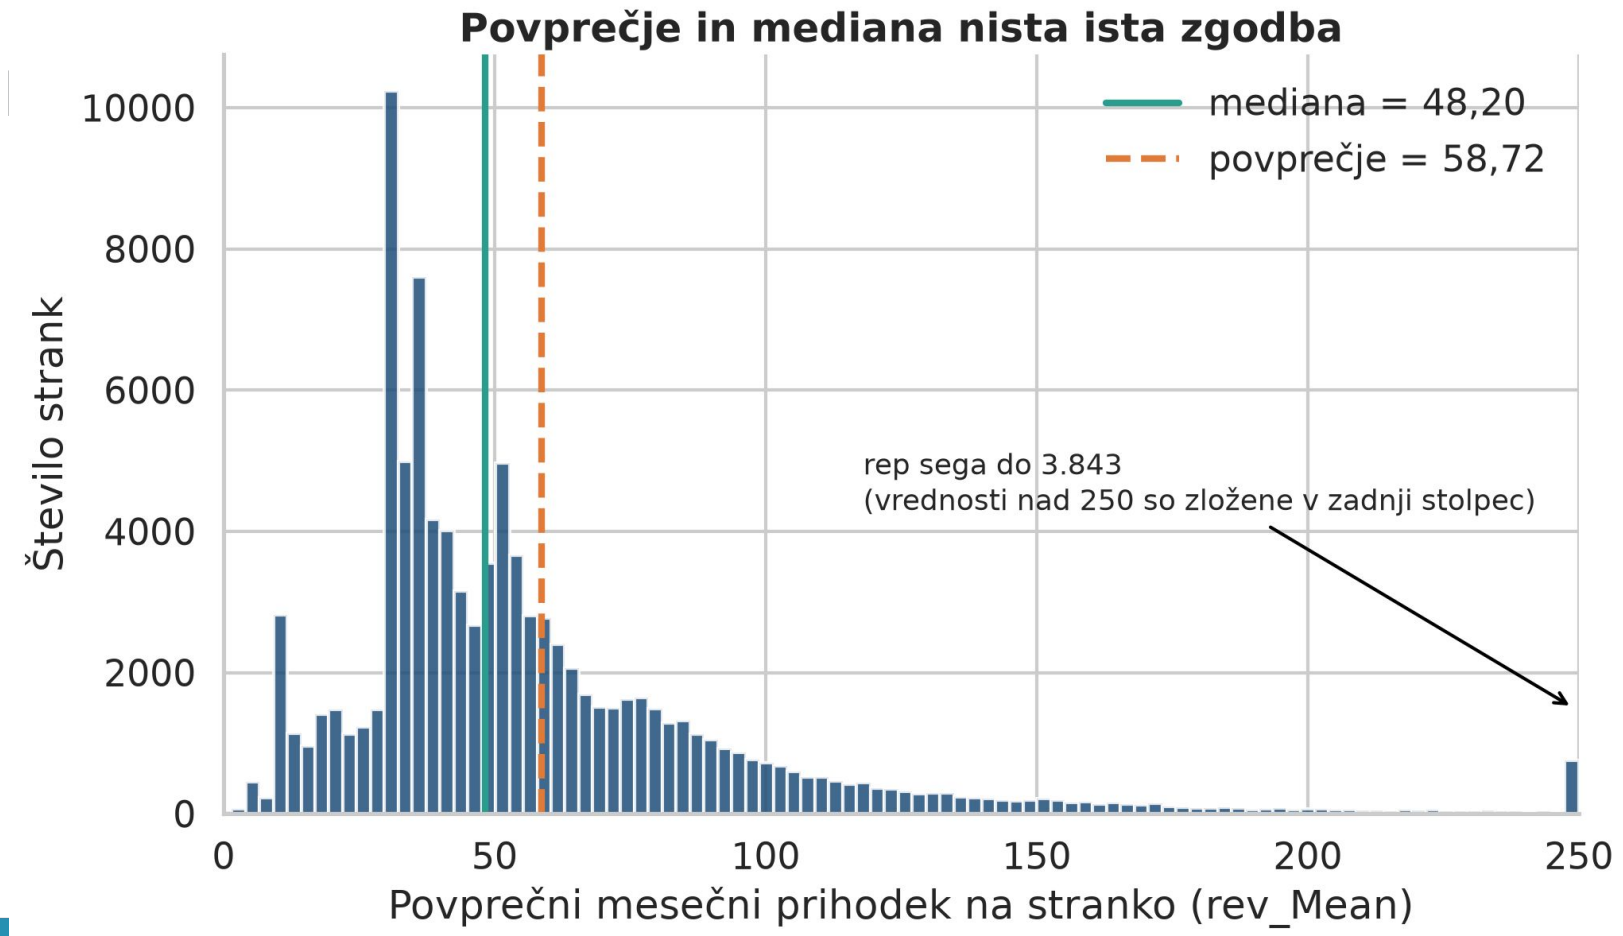
- Histogram: vrednosti razdelimo v razrede in preštejemo, koliko jih je v vsakem.
- Porazdelitev je simetrična ali asimetrična (dolg rep na eni strani).
- Več vrhov nakazuje, da je v podatkih več skupin.
- Veliko ničel pomeni, da stolpec odgovarja na dve vprašanji: ali se je nekaj zgodilo in koliko.



Shematski prikaz na umetnih podatkih.

Mere središčnosti

- Povprečje: vsota vrednosti, deljena z njihovim številom. Občutljivo je na ekstremne vrednosti.
- Mediana: srednja vrednost urejenih podatkov; polovica vrednosti je pod njo. Ekstremi nanjo ne vplivajo.
- Modus: najpogostejša vrednost. Uporaben je tudi za kategorije.
- Pri simetrični porazdelitvi sta povprečje in mediana skoraj enaka. Pri dolgem repu proti visokim vrednostim je povprečje višje od mediane.


Povprečje in mediana nista ista zgodba
mediana = 48,20
povprečje = 58,72
rep sega do 3.843
(vrednosti nad 250 so zložene v zadnji stolpec)
Število strank
0
2000
4000
6000
8000
10000
0
50
100
150
200
250
Povprečni mesečni prihodek na stranko (rev_Mean)

Mere razpršenosti

- Razpon: največja vrednost minus najmanjša. Določata ga le dve vrednosti.
- Varianca: povprečje kvadratov odmikov od povprečja. Standardni odklon je njen koren in je v enotah podatkov.
- Kvartili Q1, Q2 (mediana) in Q3 razdelijo urejene podatke na četrtine.
- Kvartilni razmik = Q3 − Q1 je razpon srednje polovice podatkov. Ekstremi nanj ne vplivajo.

Razpon	$R = x_{\max} - x_{\min}$
Varianca	$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$
Standardni odklon	$s = \sqrt{s^2}$
Interkvartilni razmik	$\mathrm{IQR} = Q_3 - Q_1$

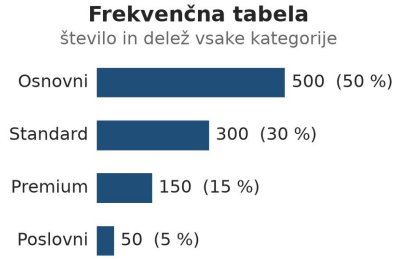
x_i je posamezna vrednost, $\bar{x}$ povprečje, n število vrednosti, Q_1 in Q_3 sta prvi in tretji kvartil.

Tip spremenljivke določa statistiko

- Zvezna numerična: povprečje, mediana, standardni odklon, kvartili.
- Diskretna numerična (malo različnih vrednosti): frekvence in mediana.
- Ordinalna (urejene kategorije): frekvence in mediana; povprečje s previdnostjo.
- Nominalna (neurejene kategorije): frekvence in modus.
- Podatkovni tip v Pandasu pove, kako je podatek shranjen, ne kaj pomeni.

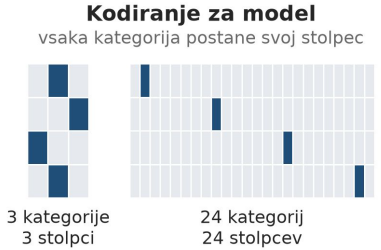
Kategorične spremenljivke

- Frekvenčna tabela: število in delež vsake kategorije.
- Kardinalnost: število različnih kategorij v stolpcu.
- Redka kategorija ima premalo primerov za zanesljive sklepe.
- Visoka kardinalnost oteži kodiranje za model (kasnejši sklop).









Shematski prikaz na umetnih podatkih.

Manjkajoče vrednosti

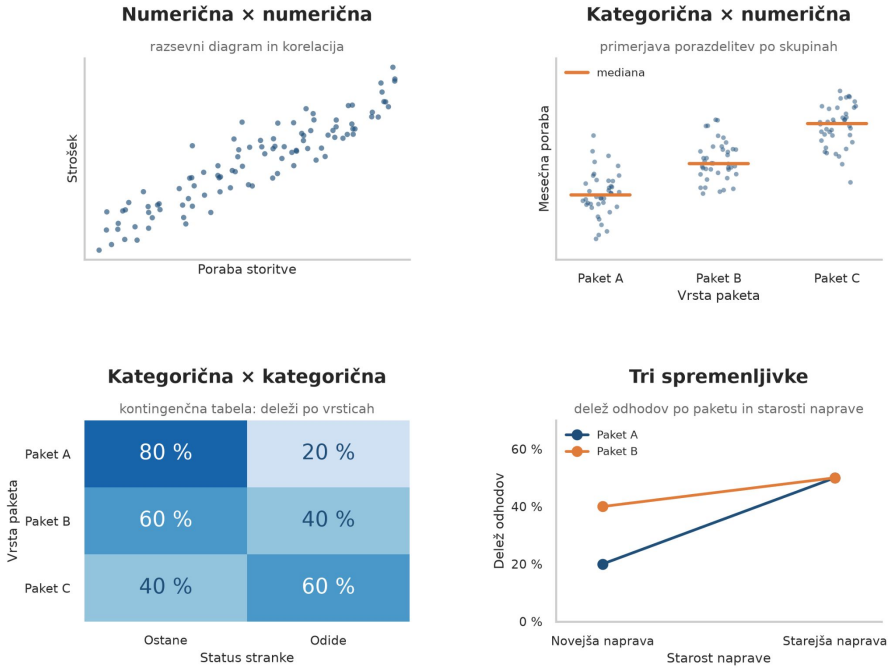
- Delež manjkajočih vrednosti po stolpcih je del opisa podatkov.
- Statistike se računajo le na znanih vrednostih.
- Manjkajoča vrednost je lahko zapisana kot NaN ali kot posebna oznaka (»neznano«, −1, 999).
- Vprašaj se, ali vrednosti manjkajo naključno ali pri določeni skupini.

Vaja 1



Odnosi med spremenljivkami

- Orodje izberemo glede na tipa obeh spremenljivk.
- Numerična in numerična: razsevni diagram in koeficient korelacije.
- Kategorična in numerična: primerjava skupin (groupby).
- Kategorična in kategorična: kontingenčna tabela (crosstab).
- Tri ali več spremenljivk: korelacijska matrika…



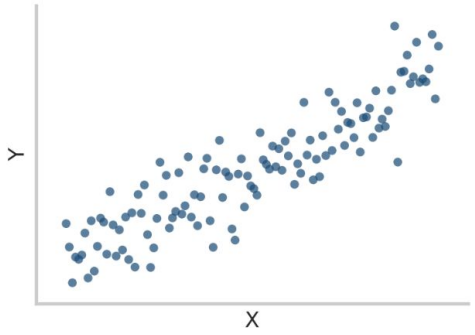
Shematski prikaz na umetnih podatkih — ne rezultati analize Telekoma ali Olista.

Korelacija: Pearson in Spearman

- Koeficient korelacije je med −1 in 1; predznak pove smer, absolutna vrednost moč povezave.
- Pearson meri linearno povezavo. Občutljiv je na ekstremne vrednosti.
- Spearman je Pearson na rangih. Meri, ali spremenljivki naraščata skupaj, tudi če ne linearno.
- Če se koeficienta opazno razlikujeta, je povezava nelinearna ali pa nanjo vplivajo ekstremi. Nariši razsevni diagram.

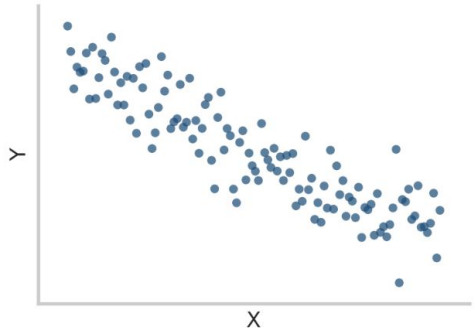
Močna pozitivna povezava

Pearson r = 0,90 | Spearman ρ = 0,91



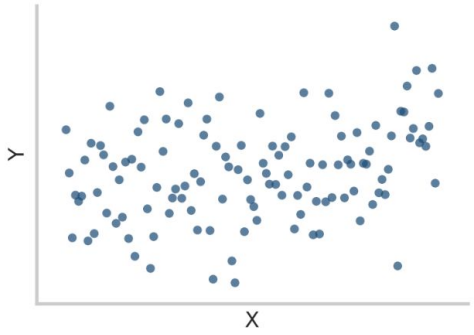
Močna negativna povezava

Pearson r = -0,90 | Spearman ρ = -0,90



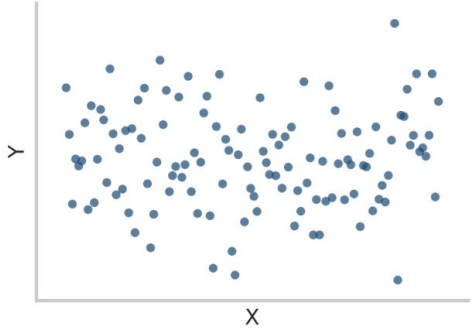
Šibka linearna povezava

Pearson r = 0,30 | Spearman ρ = 0,29



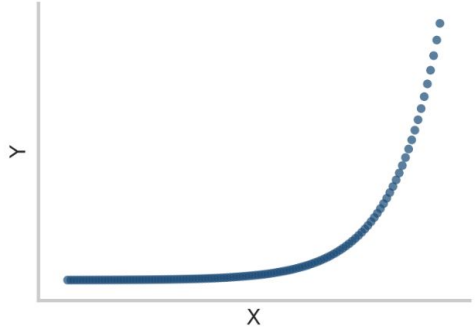
Brez linearnega trenda

Pearson r = 0,00 | Spearman ρ = -0,01



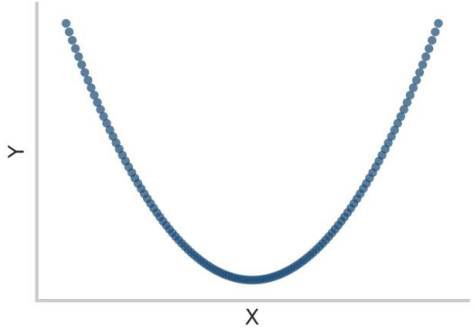
Monotona, a nelinearna

Pearson r = 0,75 | Spearman ρ = 1,00



Povezava v obliki črke U

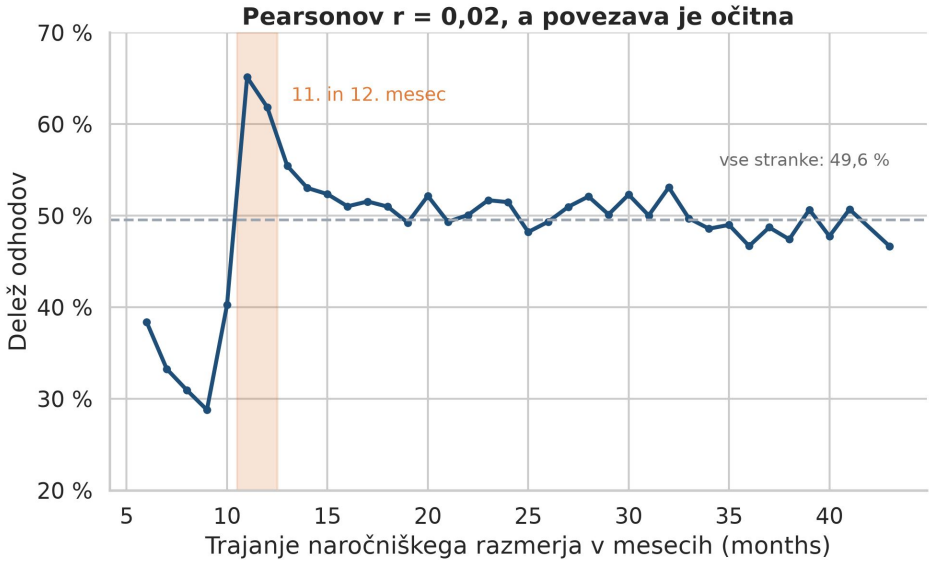
Pearson r = 0,00 | Spearman ρ = -0,01



Shematski primeri na umetnih podatkih. Koeficienti so izračunani iz prikazanih točk.

Česa koeficient korelacije ne vidi

- Koeficient blizu 0 pomeni, da ni linearne oziroma enakomerno naraščajoče povezave.
- Povezava lahko vseeno obstaja: v obliki črke U, s pragom ali z izrazitim vrhom.
- Koeficient je ena številka; oblike povezave ne opiše.
- Zato povezavo vedno tudi narišemo.

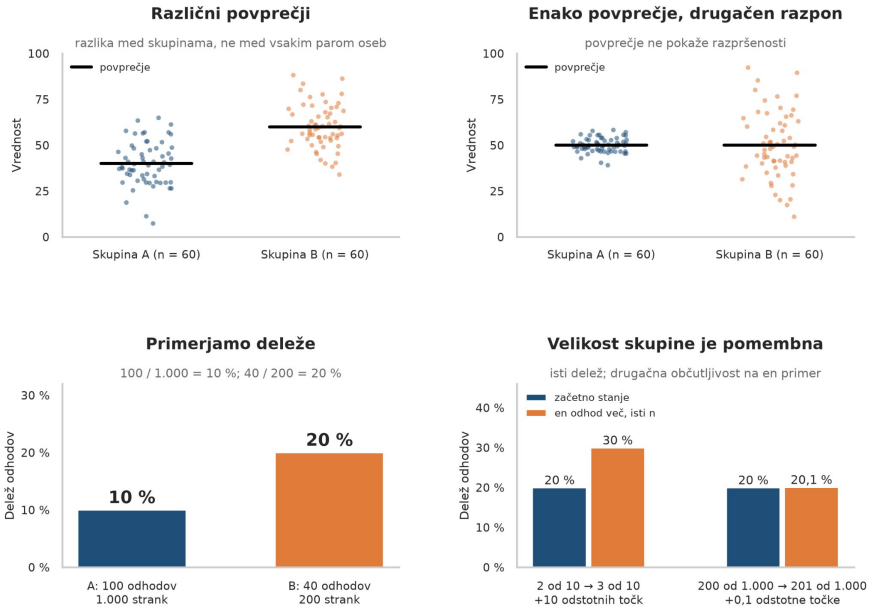


Korelacija s ciljno spremenljivko

- Ciljna spremenljivka je tisto, kar želimo napovedati.
- Razvrstitev značilk po korelaciji s ciljem je hiter prvi pregled.
- Šibka korelacija posamezne značilke je običajna; model združi več šibkih signalov.
- Pregled zgreši nelinearne povezave in kombinacije značilk.

Primerjava skupin

- Podatke razdelimo po kategoriji in za vsako skupino izračunamo isto statistiko.
- Pri numerični spremenljivki primerjamo povprečje ali mediano, pri binarni delež.
- Povprečje binarne spremenljivke (0/1) je delež enic.
- Vedno izpiši tudi velikost skupine; razlika v majhni skupini je nezanesljiva.



Samostojni shematski primeri na umetnih podatkih. Razlika med skupinama ni dokaz vzročnosti.

Kontingenčna tabela

- Kontingenčna tabela prešteje primere za vsako kombinacijo dveh kategorij.
- Za primerjavo skupin različnih velikosti števila pretvorimo v deleže.
- Deleži po vrsticah in deleži po stolpcih odgovarjajo na različni vprašanji.
- Smer izberemo glede na vprašanje, ki ga postavljamo.

Število strank

Koliko strank je v vsaki kombinaciji?

	Ostane	Odide	Skupaj
Paket A	720	**180**	900
Paket B	60	**40**	100
Skupaj	780	220	1.000

Paket A: 180 odhodov
Paket B: 40 odhodov

Deleži po vrsticah

Kolikšen delež strank paketa odide?

	Ostane	Odide	Skupaj
Paket A	80,0 %	**20,0 %**	100 %
Paket B	60,0 %	**40,0 %**	100 %

A: 180 / 900 = 20 %
B: 40 / 100 = 40 %

Deleži po stolpcih

Kateri paket imajo stranke, ki odidejo?

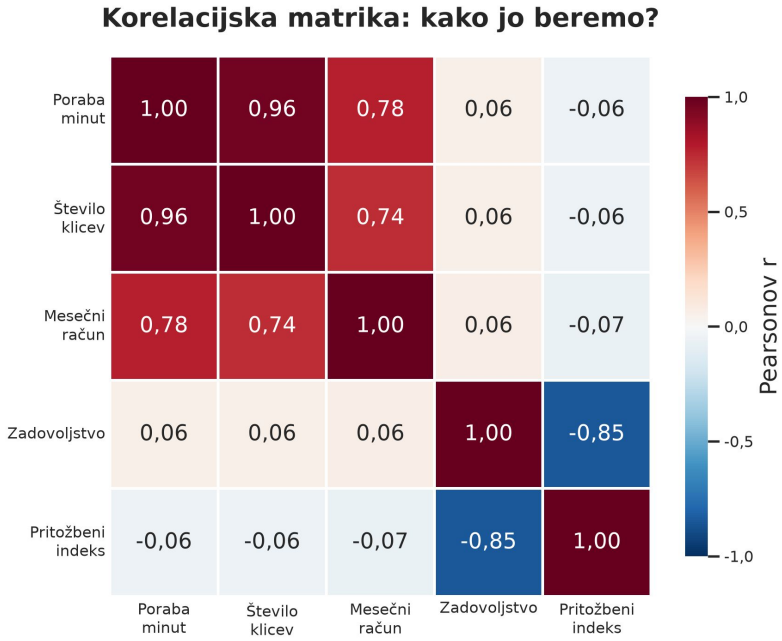
	Ostane	Odide
Paket A	92,3 %	**81,8 %**
Paket B	7,7 %	**18,2 %**
Skupaj	100 %	100 %

Med odhodi ima paket A:
180 / 220 = 81,8 %

Isti izmišljeni podatki: 1.000 strank. Oranžno so označene celice z odhodi.

Korelacijska matrika in podvojene značilke

- Korelacijska matrika prikaže koeficiente za vse pare numeričnih spremenljivk.
- Toplotna karta pokaže skupine močno povezanih značilk.
- Par z zelo visoko korelacijo nosi skoraj isto informacijo (multikolinearnost).
- Posledica: nestabilni koeficienti linearnih modelov in zavajajoča pomembnost značilk.



Umetni podatki (n = 1.500); koeficienti so izračunani, ne ročno določeni.

Korelacija ni vzročnost

- Povezanost dveh spremenljivk ne pove, katera vpliva na katero.
- Moteča spremenljivka vpliva na obe opazovani in ustvari ali poveča navidezno povezavo.
- Preverimo jo tako, da povezavo pogledamo znotraj skupin z enako vrednostjo moteče spremenljivke.
- Vzročnost dokažemo s poskusom (na primer A/B-testom), ne z opisno statistiko.

Vaja 2



Povzetek

- Stolpec opišemo s sredino, razpršenostjo in obliko porazdelitve.
- Statistiko izberemo glede na tip spremenljivke in obliko porazdelitve.
- Orodje za odnos med spremenljivkama izberemo glede na njuna tipa.
- Koeficient korelacije opiše le enakomerne povezave, zato povezavo tudi narišemo.
- Povezanost še ni vzročnost.



Vizualizacija podatkov

Kako izbrati pravi graf?

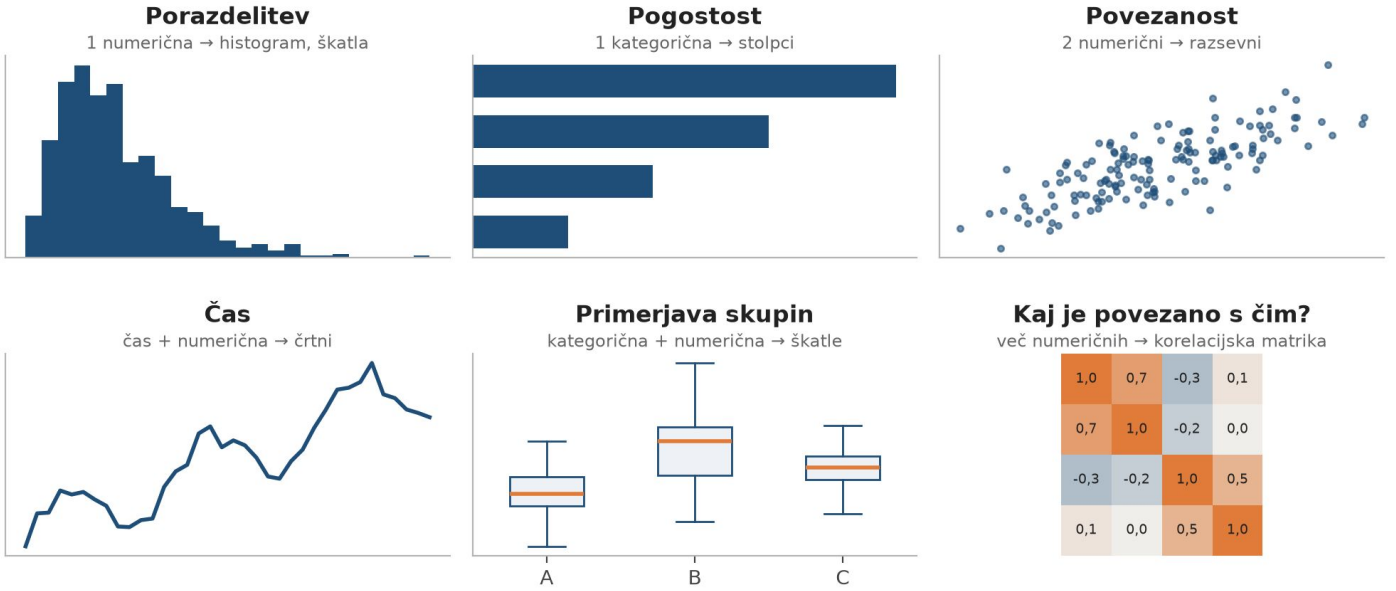
Graf izberemo po vprašanju in tipu podatkov

- Najprej vprašanje, nato tip spremenljivk — šele potem graf:

VPRAŠANJE	SPREMENLJIVKE	GRAF
Kako so vrednosti porazdeljene?	1 numerična	Histogram + KDE, škatla z brki
Kako pogoste so kategorije?	1 kategorična	Stolpični diagram
Ali sta povezani?	2 numerični	Razsevni diagram
Kako se spreminja v času?	Čas + numerična	Črtni graf
Ali se skupine razlikujejo?	Kategorična + numerična	Škatle / violine po skupinah
Kaj je povezano s čim?	Več spremenljivk	Korelacijska matrika; barva in podgrafi

Graf izberemo po vprašanju in tipu podatkov

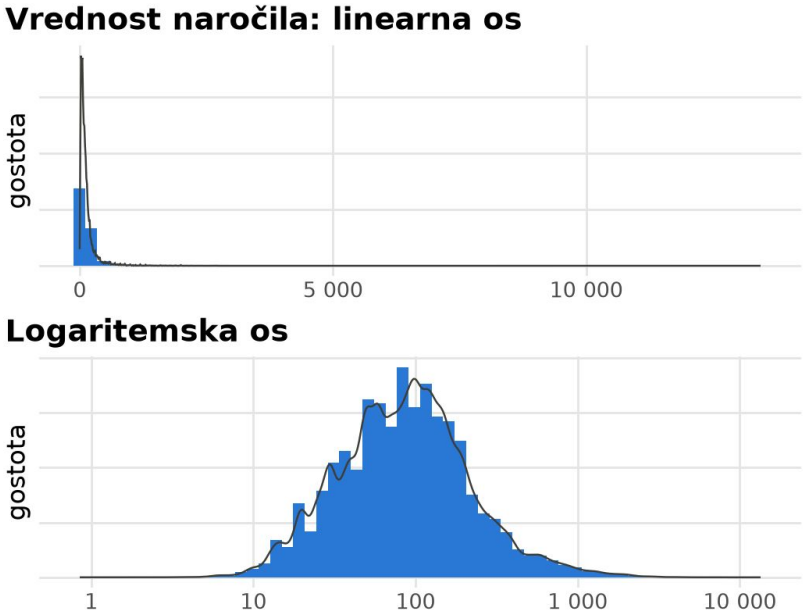
- Najprej vprašanje, nato tip spremenljivk — šele potem graf:



Shematski prikaz na umetnih podatkih.

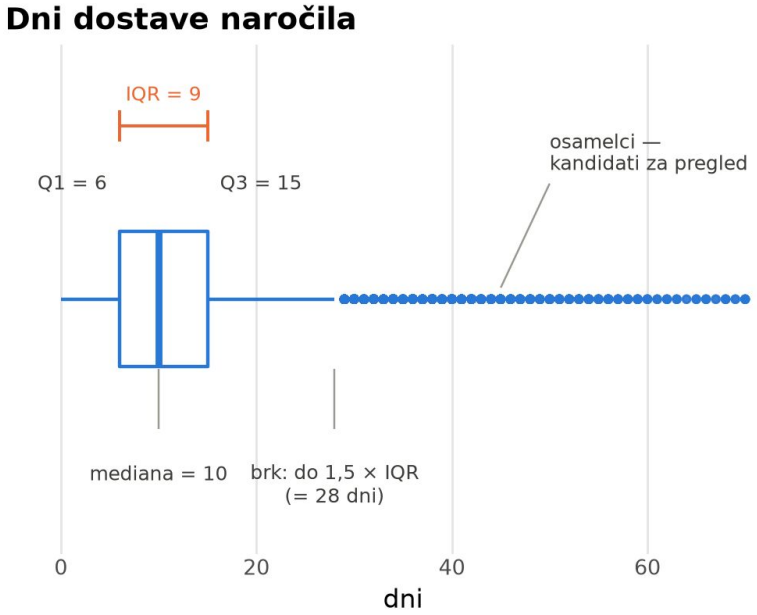
Porazdelitev: histogram in KDE

- **Histogram**: vrednosti razdeli v razrede in prešteje, koliko jih pade v vsakega.
- **KDE**: zglajena krivulja iste porazdelitve.
- Iščemo:
- kje je glavnina vrednosti,
- ali je porazdelitev simetrična ali ima **dolg rep**,
- ali ima **več vrhov** (morda različne skupine).
- Dolg rep → **logaritemska os**.
- Pozor: število razredov spremeni sliko.

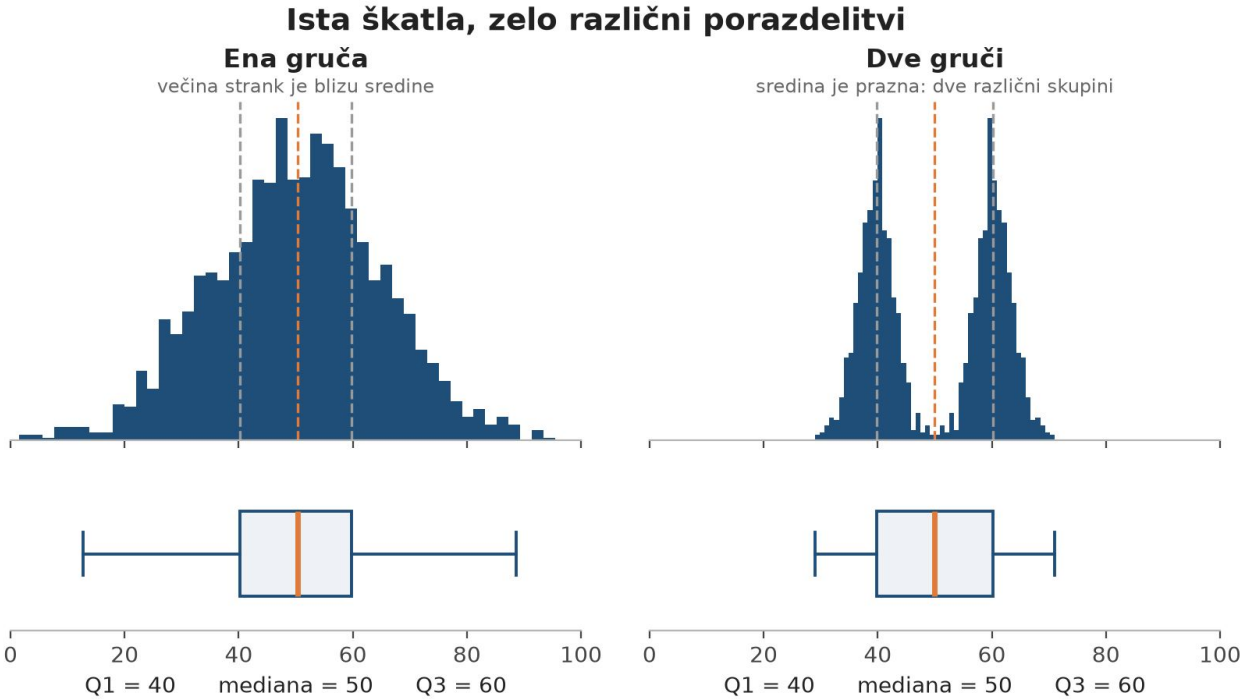


Škatla z brki (boxplot)

- **Škatla:** srednjih 50 % podatkov, od Q1 do Q3.
- **Črta v škatli:** mediana.
- **IQR** = Q3 − Q1 — razpon srednje polovice.
- **Brki:** do najbolj oddaljene vrednosti znotraj 1,5 × IQR.
- **Točke zunaj brkov:** kandidati za osamelce → popoldne.
- **Prednost:** kompakten, več skupin primerjamo eno ob drugi.
- **Slabost:** skrije obliko (dveh vrhov ne vidimo).



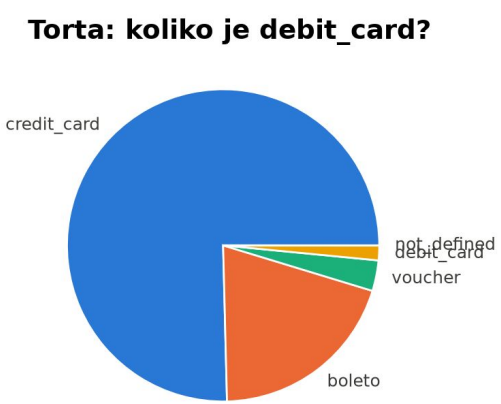
Škatla z brki ALI Poradelitev

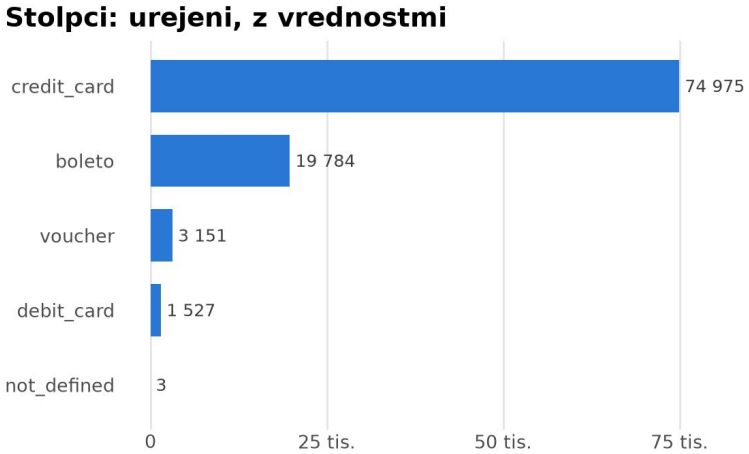


Shematski prikaz na umetnih podatkih. Črtkano: Q1, mediana (oranžno) in Q3.

Ena kategorična: stolpični diagram

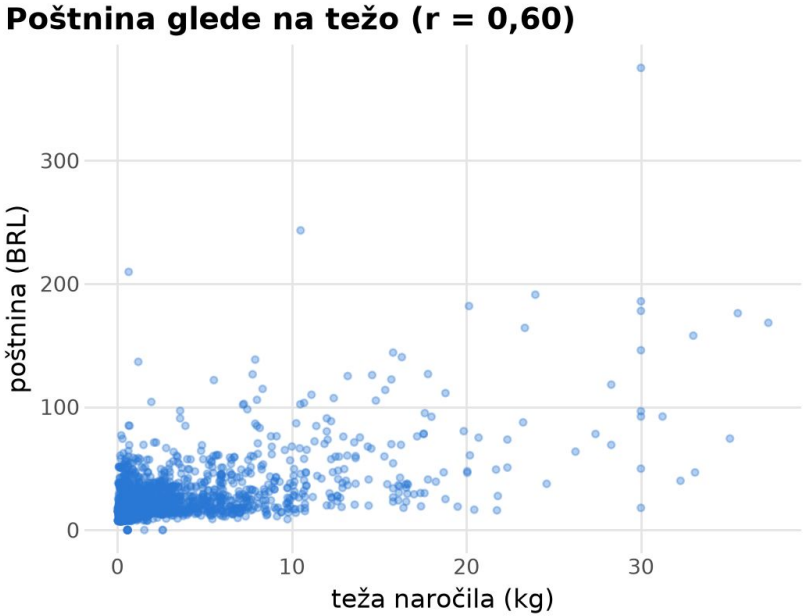
- **Stolpični diagram (count plot)**: ena kategorija = en stolpec, dolžina = pogostost.
- Stolpce **uredimo po velikosti;** pri dolgih imenih jih obrnemo vodoravno.
- Veliko kategorij ⟶ top 10 + »ostalo«.
- **Torta** samo za 2–3 deleže celote — oko slabo primerja kote in ploščine.





Dve numerični: razsevni diagram

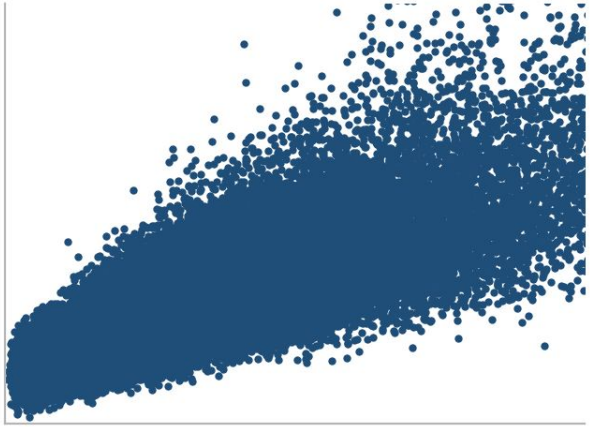
- Ena točka = eno opazovanje (naročilo).
- Iščemo: **smer, obliko, moč** povezave, skupine in točke daleč od drugih.
- Veliko točk → **vzorec** in **prosojnost** (alpha).
- **Pearsonov r** povzame linearno povezanost (od −1 do +1).
- Povezanost ≠ vzročnost.



Razsevni diagram: praktični nasvet

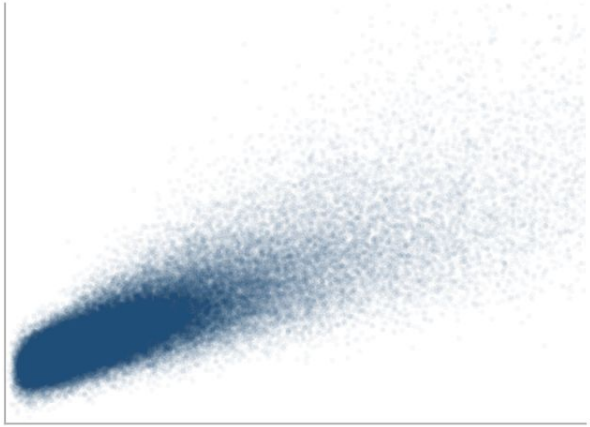
100 000 točk

vse se zlije v en madež



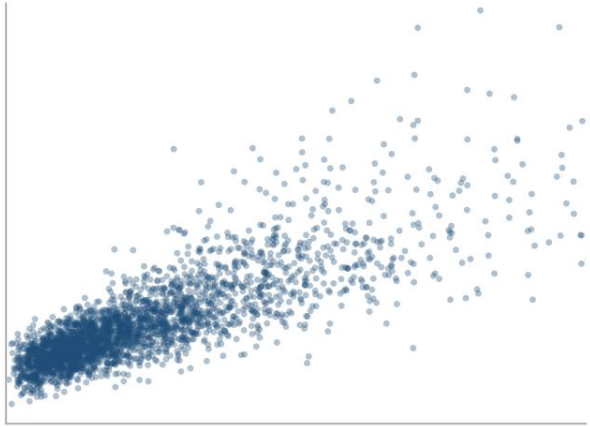
+ prosojnost

alpha = 0,03: vidimo, kje je največ točk



vzorec 3 000 točk + prosojnost

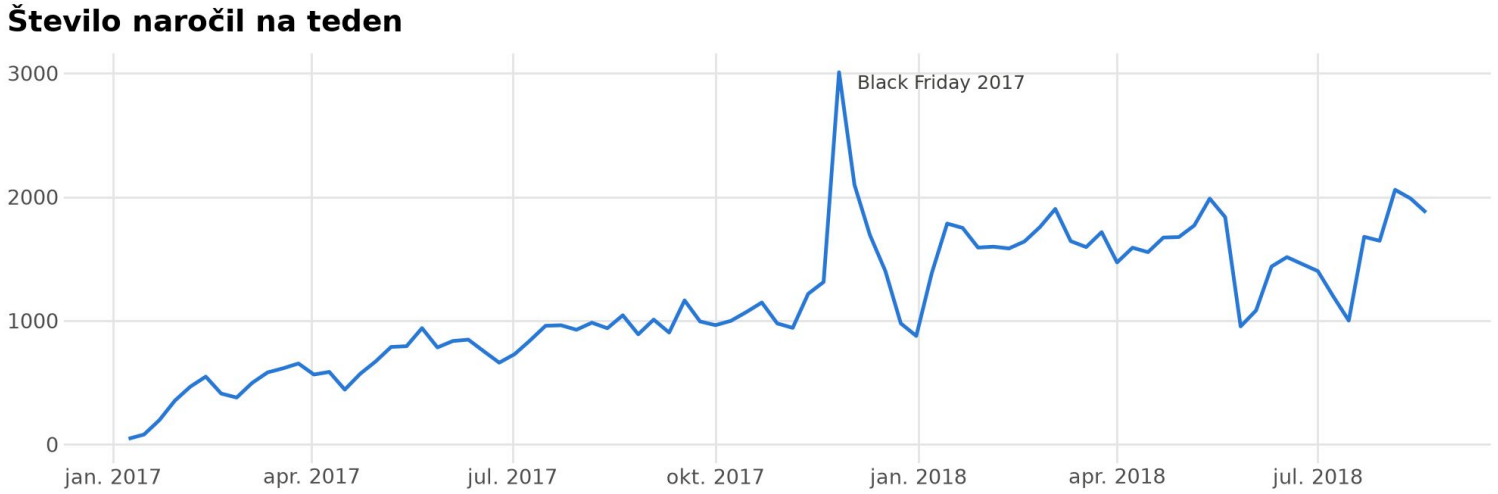
hitreje, oblika ostane



Shematski prikaz na umetnih podatkih.

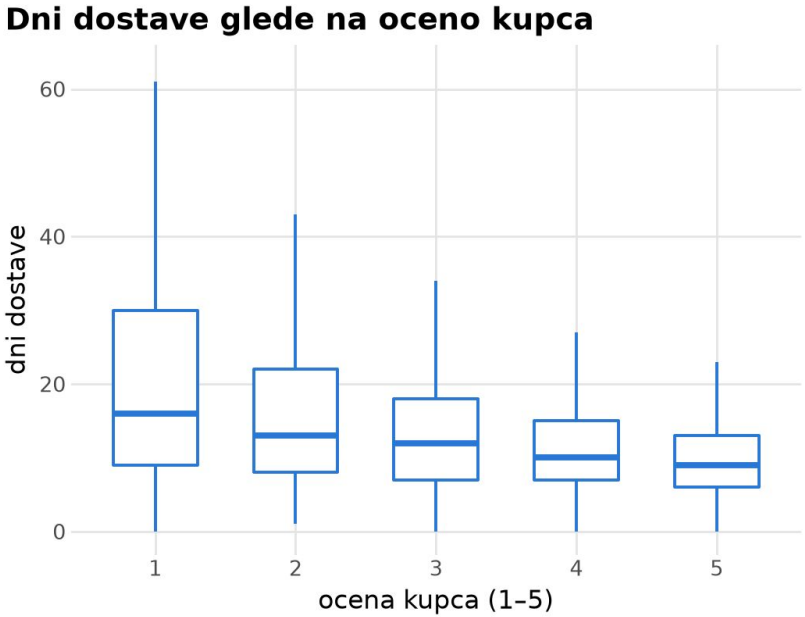
Čas: črtni graf

- Čas na osi x, vrednost na osi y; točke povežemo, ker si sledijo.
- Iščemo: **trend, sezonskost, enkratne dogodke.**
- Agregiramo na smiselno obdobje (dan / teden / mesec).



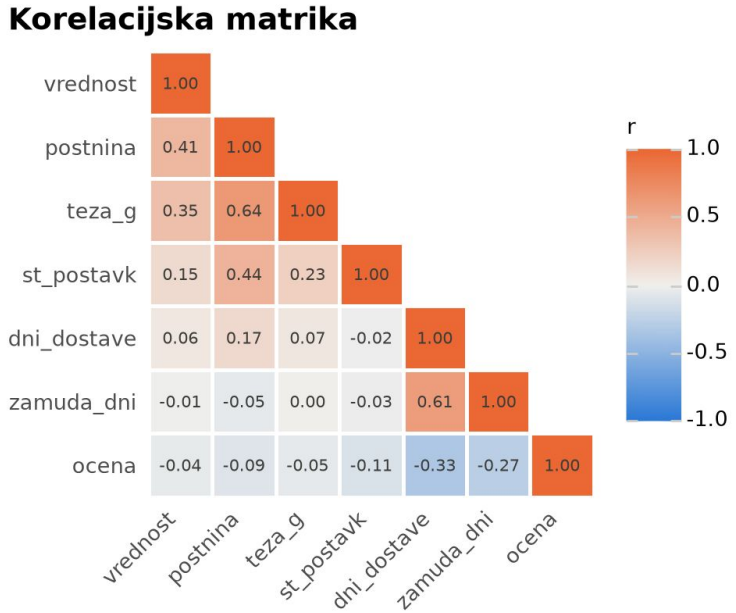
Kategorična + numerična: primerjava skupin

- Škatle ali violine **ena ob drugi** — ena za vsako skupino.
- Trgovina: dlje kot je kupec čakal na dostavo, slabšo oceno je dal.
- Telekom: so stranke, ki odidejo, drugačne od tistih, ki ostanejo?
- **Violina** = škatla + oblika porazdelitve.



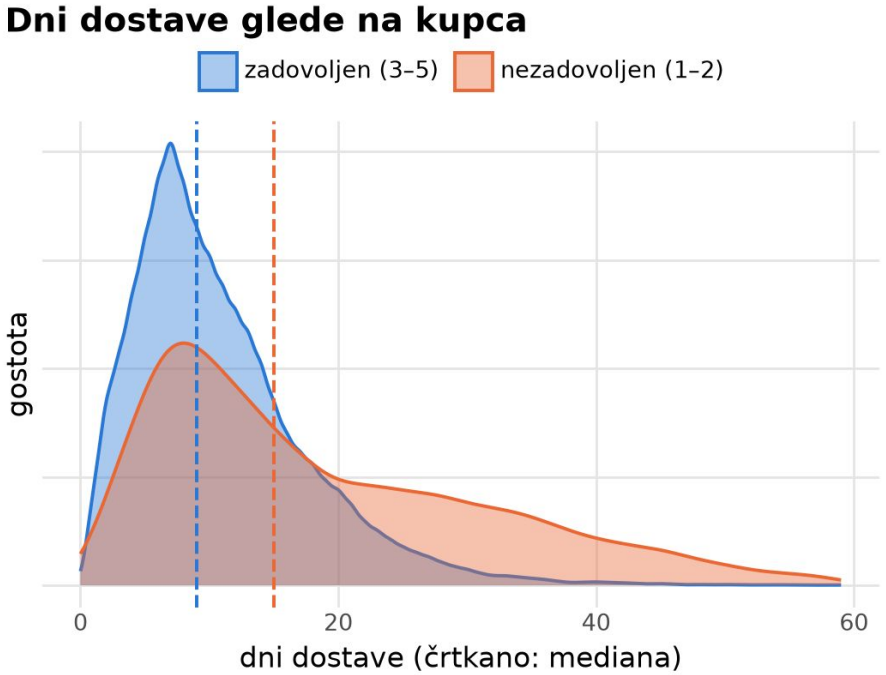
Več spremenljivk: korelacijska matrika

- Korelacija vsakega para numeričnih spremenljivk na eni sliki.
- **Oranžna**: pozitivna,
- **Modra**: negativna,
- Siva: ≈ 0.
- Uporaba:
  - **podvojene** informacije (poštnina ↔ teža),
  - kandidati za napovedovanje (dni dostave ↔ ocena).
- Meri samo **linearno** povezanost.
- Ne pove, kaj je vzrok in kaj posledica.



Tretja spremenljivka: barva in podgrafi

- **Barva** (`fill=`, `color=`): doda kategorično spremenljivko — tu zadovoljen / nezadovoljen kupec.
- **Podgrafi** (`facet_wrap`): isti graf za vsako skupino posebej, eden ob drugem.
- Iščemo: kje se skupini ločita?
- Dni dostave (mediana): nezadovoljni **15**, zadovoljni **9**.



Pogoste napake

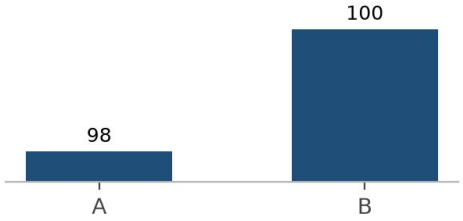
- **Odrezana os y** pri stolpcih → majhne razlike izgledajo velike.
- **Dve osi y** na enem grafu → z izbiro merila lahko pokažemo karkoli.
- **3D in sence** → popačijo dolžine in kote.
- **Preveč barv** → barva naj nosi pomen, ne služi okrasu.
- **Torta z veliko rezinami.**
- **Samo povprečje** → raje škatla, ki pokaže tudi razpršenost.
- Vsak graf: **naslov, oznake osi, enote**.

Pogoste napake

Slabo

Odrezana os y

os se začne pri 97,5: B je videti 3-krat večji



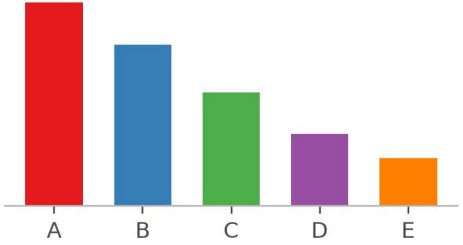
Samo povprečje

skupini sta videti enaki



Preveč barv

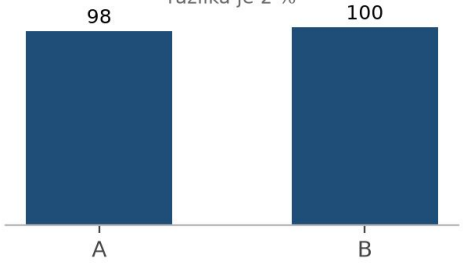
barva ne pomeni ničesar



Bolje

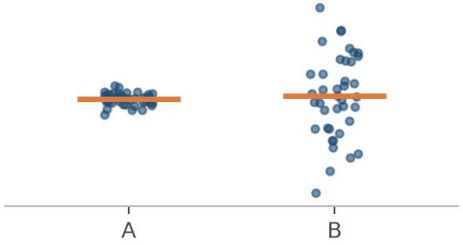
Os od 0

razlika je 2 %



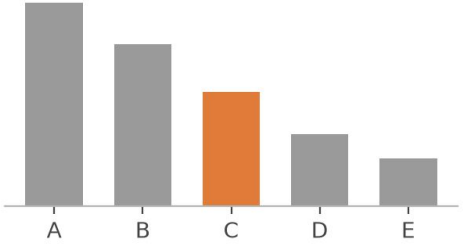
Točke + povprečje

B je veliko bolj razpršena



Barva s pomenom

poudarimo samo, kar je pomembno



Shematski prikaz na umetnih podatkih.

Hands-on 3: vizualna analiza

- Zvezek `B_vizualizacija` – telekom; zamenjajte ime stolpca in ponovno zaženite celico.
- **Za razmislek** (slika): katere vrednosti ne morejo biti res? Kje se skrivajo manjkajoči podatki?

