

SLAIF
Slovenska tovarna UI

Slovenian AI Factory

Eksplorativna analiza podatkov

Od raziskovanja do priprave podatkov

- V prvem sklopu smo opisali porazdelitve in odnose.
- Zdaj preverimo, ali podatkom lahko zaupamo.
- Cilj ni »lepša tabela«, temveč smiselni in uporabni podatki.

Kaj predstavlja ena vrstica?

- Določimo enoto opazovanja: stranka, naročilo, postavka ali dogodek.
- Določimo ključ, ki mora biti na tej ravni enoličen.
- Ponovljen ID ni nujno podvojitev: naročilo lahko vsebuje več postavk.

Naročilo	Postavka
N1	1
N1	2
N2	1



Naročilo: 2 različna ID-ja

(Naročilo, postavka):
3 različni ključi

Hiter pregled kakovosti

- Struktura: tipi stolpcev, ključi in podvojitve.
- Popolnost: kaj manjka, koliko in pri katerih skupinah?
- Veljavnost: dovoljen razpon vrednosti, enote in kategorije.
- Skladnost: ali si povezani stolpci nasprotujejo?
- Kontekst: izvor, obdobje zajema in pravila nastanka podatkov.

Neobičajno še ni napačno

- Ekstremna vrednost je kandidat za pregled, ne avtomatsko za izbris.
- Manjkajoči podatek je lahko pričakovan glede na stanje procesa.
- Pravila preverjanja izpeljemo iz pomena podatkov.
- Pred posegom preverimo vir ali poslovno razlago.

Status	Datum dostave		
V obdelavi	—	→	Pričakovano
Dostavljeno	—	→	Preveri neskladje

Od opažanja do preverljive odločitve

- Zapišemo opažanje in obseg: koliko vrstic zadeva?
- Postavimo možno razlago in način preverjanja.
- Izberemo utemeljeno obravnavo; izvirne podatke ohranimo.
- Po spremembi preverimo vrstice, ključe in porazdelitve.



Obravnava manjkajočih vrednosti

Kako jih odkrijemo in kaj z njimi naredimo?

Kako se pojavijo manjkajoče vrednosti?

- **NaN / None**: Pandas jih prepozna sam.
- **Prazen niz** `""`: včasih se prebere kot besedilo.
- **Posebne oznake**: `"U"`, `"UNKW"`, `-1`, `999`, `1900-01-01`.
  - Pandas jih ne prepozna → `read_csv(na_values=...)`
- Telekom: `zakonski_stan` manjka pri **2 %** strank … ali pri **39 %**?

V datoteki	Pandas prebere	isna()
(prazna celica)	NaN	True
NA	NaN	True
U	**"U"**	**False**
UNKW	**"UNKW"**	**False**
-1	**-1**	**False**
999	**999**	**False**
1900-01-01	**"1900-01-01"**	**False**

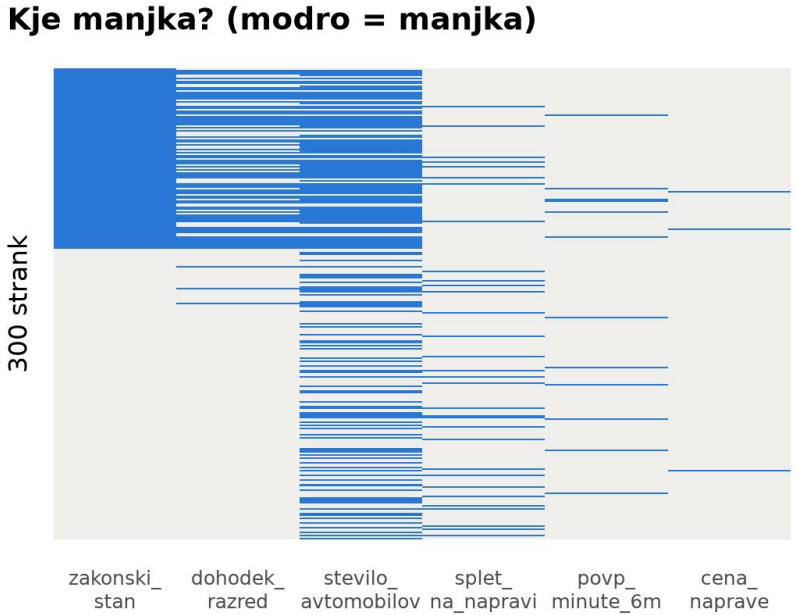
Oranžno: manjkajoča vrednost, ki je Pandas ne prepozna
→ povemo mu jo z read_csv(na_values=...)

Manjkajoča vrednost ni isto kot ničla

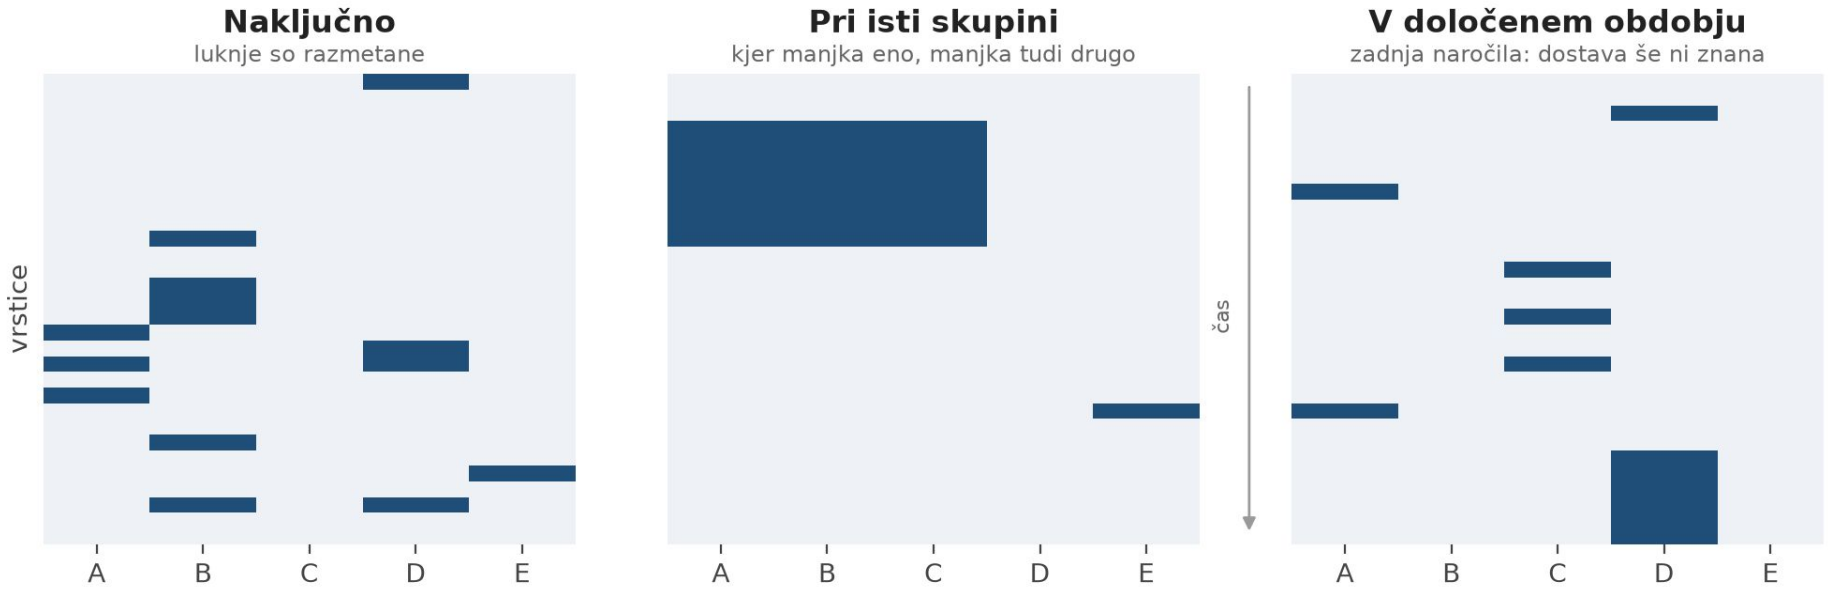
- **0 nakupov** → stranka v obdobju ni kupovala. To je podatek.
- **NaN nakupov** → podatek ni bil zajet. Vrednosti ne poznamo.
- Telekom:
  - `povp_minute = 0` → **1615** strank ni klicalo,
  - `povp_minute = NaN` → pri **357** strankah ne vemo.
- `fillna(0)` bi 357 strankam pripisal, da telefona ne uporabljajo.
- Včasih manjka **z razlogom**: povprečje zadnjih 6 mesecev manjka skoraj samo pri **novih strankah.**

Delež in vzorci manjkajočih vrednosti

- Najprej **delež:** `df.isna().mean()`
- Nato **vzorec**: ali manjka naključno?
  - **V določenem obdobju?** Zamenjava sistema, zadnja naročila pred izvozom.
  - **Pri določenem tipu strank?** Nove stranke, določena regija.
- Telekom: kjer manjka zakonski stan, manjkata tudi **dohodek** in **število avtomobilov.**
- Če ne manjka naključno → vsaka obravnava lahko popači sliko.



Delež in vzorci manjkajočih vrednosti



Shematski prikaz na umetnih podatkih. Modro = vrednost manjka.

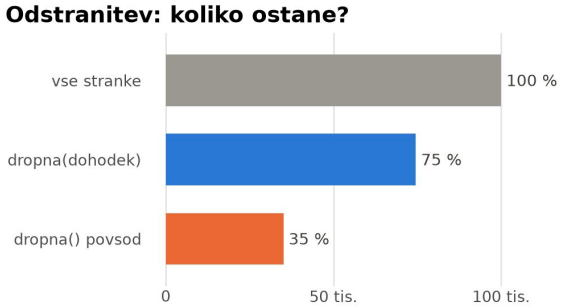
Možnosti obravnave

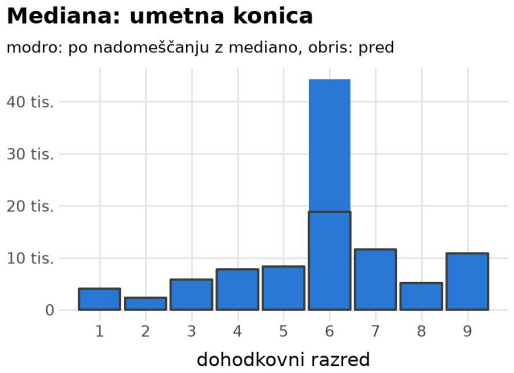
- Ni ene prave metode – izbira je odvisna od **razloga**, zakaj manjka:

METODA	KDAJ	TVEGANJE
Odstranitev vrstic	Manjka malo in naključno	Izgubimo podatke, pristranskost
Odstranitev stolpca	Manjka skoraj vse	Izgubimo informacijo
Mediana / povprečje	Numerični stolpec	Umetna konica, manjša razpršenost
Najpogostejša kategorija	Kategorični, manjka malo	Napihne največjo skupino
Oznaka »neznano«	Kategorični stolpec	Nova kategorija
Indikator manjkanja	Manjkanje nosi informacijo	En stolpec več

Prikaz: odstranitev ali mediana?

- `dropna()` povsod → ostane samo **35 %** strank.
  - Ostanejo predvsem stranke z znanim zakonskim stanom → **pristranskost**.
- **Mediana** → ostanejo vse stranke, a četrtina dobi razred 6.
  - Umetna konica, manjša razpršenost.
- Pri dolgem repu: **mediana**, ne povprečje (povprečje potegnejo ekstremi).





Varovalka: uhajanje podatkov (data leakage)

- Za model podatke razdelimo na **učne** in **testne.**
  - Testni = "nove stranke", ki jih model še ni videl.
- Mediano in druge parametre predprocesiranja **izračunamo samo na učnih** podatkih.
- Isto številko uporabimo tudi na testnih.
- Sicer informacija iz testnih podatkov "uhaja" v model → rezultat je preveč optimističen.
- `SimpleImputer(strategy="median").fit(ucni)`
- V zvezku to že upoštevamo. Podrobneje v **3. sklopu**.



Shematski prikaz na umetnih podatkih. Mediana dohodkovnega razreda v učnih podatkih telekoma je 6.

Hands-on: manjkajoče vrednosti v spletni trgovini

- Zvezek `B_manjkajoce_vrednosti.ipynb`
- Poglejte, **pri katerih naročilih** manjka (po statusu, po mesecih).
- Obravnavajte **en numerični** in **en kategorični** stolpec.
  - Spremenite samo `STOLPEC` in ponovno zaženite.
- Zapišite, **zakaj** ste izbrali ta pristop.
- **Ključno sporočilo: univerzalno pravilne metode za nadomeščanje ni.**



Detekcija in obravnava osamelcev

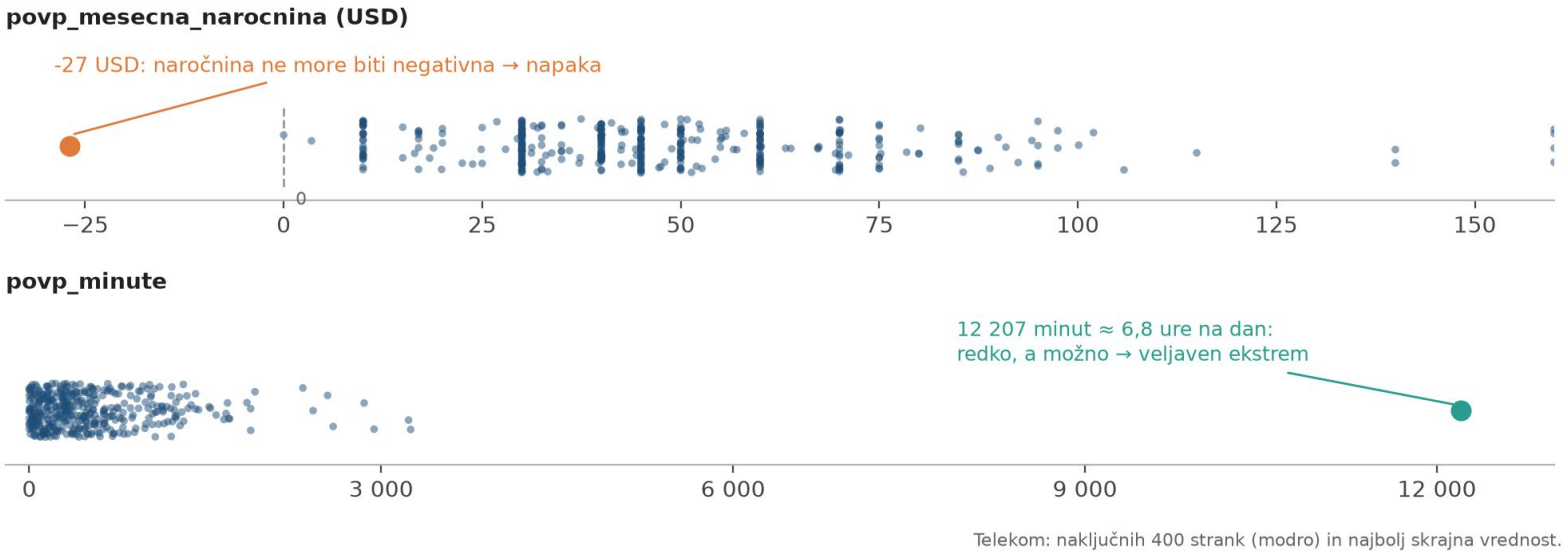
Napaka ali najzanimivejši podatek?

Kaj je osamelec?

- **Osamelec**: vrednost, ki močno odstopa od ostalih.
- Lahko je:
  - **napaka** — vrednost je nemogoča (vnos, prenos, napačna enota),
  - **veljaven ekstrem** — redka, a resnična vrednost.
- Telekom:
  - naročnina **−27 USD** na mesec ⟶ nemogoče,
  - **12 206 minut** na mesec ⟶ redko, a možno.
- Zakaj je pomembno?
  - Povprečje in mnogi modeli so **občutljivi** na ekstreme.
  - Ekstremi so pogosto **najpomembnejše stranke**, goljufije ali okvare.

Kaj je osamelec?

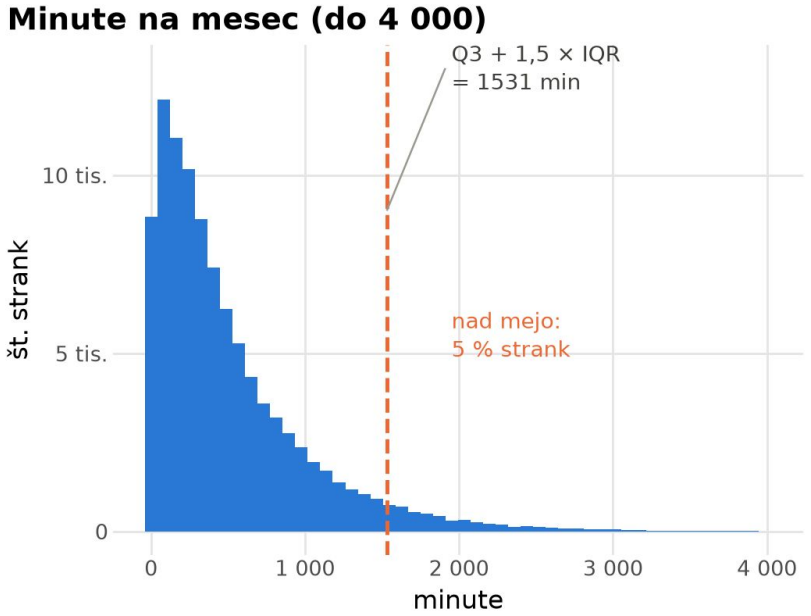
- Telekom:
  - naročnina **−27 USD** na mesec ⟶ nemogoče,
  - **12 206 minut** na mesec ⟶ redko, a možno.



Telekom: naključnih 400 strank (modro) in najbolj skrajna vrednost.

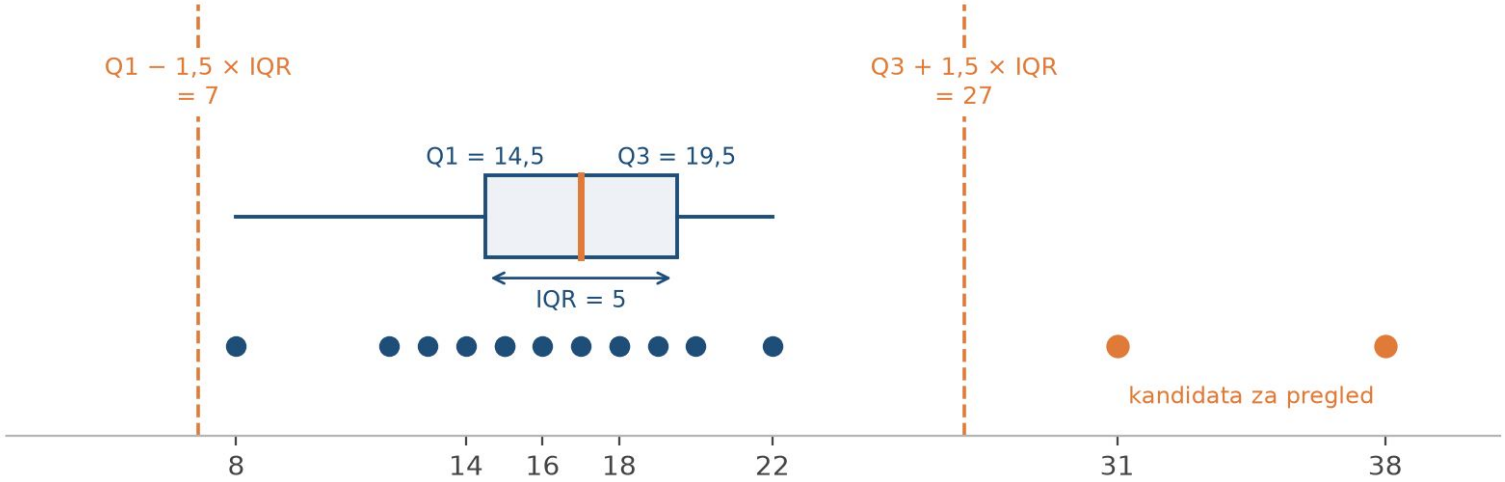
Odkrivanje: histogram, škatla z brki, pravilo IQR

- Najprej **graf**: histogram, škatla z brki.
- **Pravilo IQR**:
  - IQR = Q3 − Q1
  - kandidati: pod **Q1 − 1,5 × IQR** ali nad **Q3 + 1,5 × IQR**
  - = točke zunaj brkov
- Hitro, a **ne pozna poslovanja**:
  - minute: označi **5 %** strank,
  - gostovanje: označi **19 %** (večina ima 0),
  - naročnina: ujame **1 od 23** negativnih.



Odkrivanje: histogram, škatla z brki, pravilo IQR

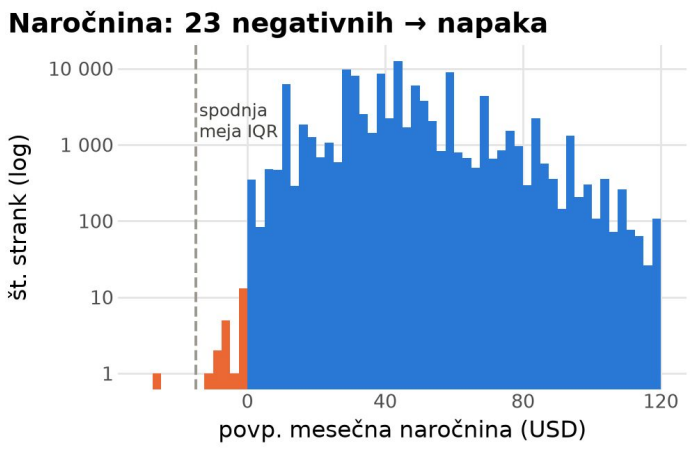
- **Pravilo IQR**:
  - IQR = Q3 − Q1
  - kandidati: pod **Q1 − 1,5 × IQR** ali nad **Q3 + 1,5 × IQR**
  - = točke zunaj brkov

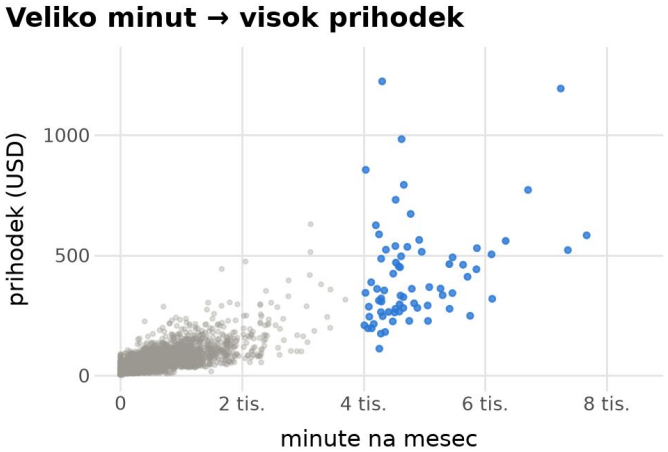


Shematski prikaz na umetnih podatkih. 15 vrednosti.

Domenske omejitve in povezani stolpci

- **Domenske omejitve**: pravila iz poslovanja, ne iz statistike.
  - Naročnina ≥ 0, dni z napravo ≥ 0, teža izdelka > 0 g.
- **Povezani stolpci**: kaj pravijo ostali podatki iste stranke?
  - Negativna naročnina, pozitiven prihodek ⟶ stolpca si nasprotujeta.
  - Veliko minut **in** visok prihodek ⟶ podatki se ujemajo.





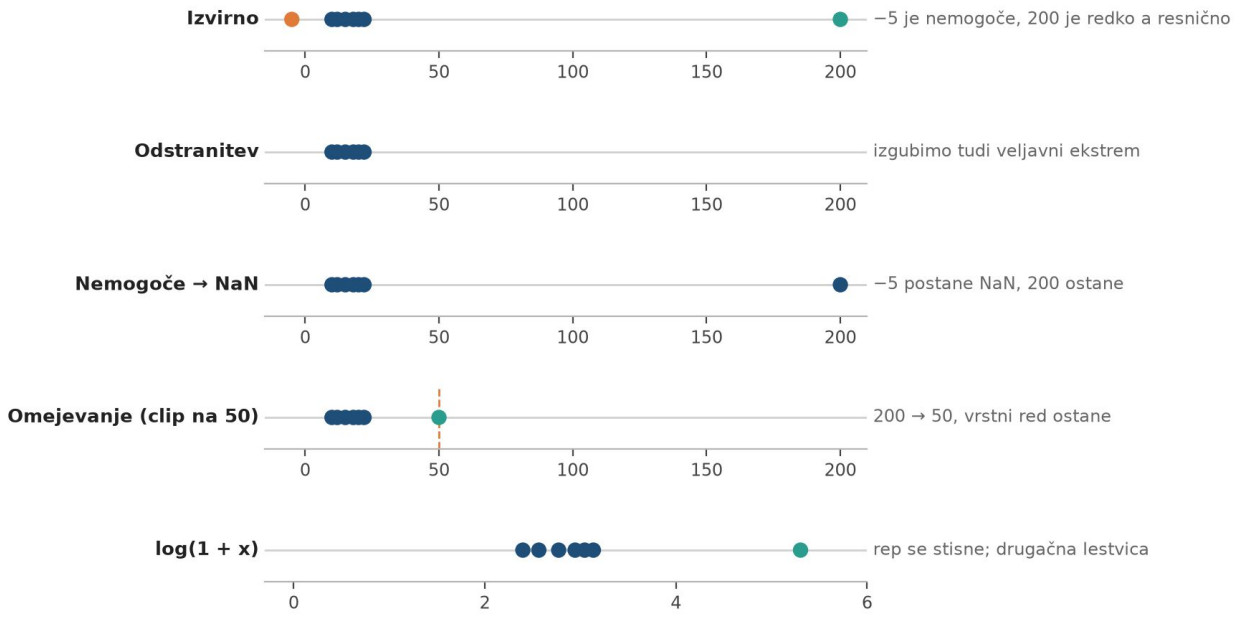
Možni odzivi

- Ko vemo, ali gre za napako ali ekstrem, izberemo odziv:

ODZIV	KDAJ	PRIMER
Popravek iz preverjenega vira	Imamo izvorni sistem	Naročnino preverimo v obračunu
Označimo kot manjkajočo	Vrednost je nemogoča	Negativna naročnina → NaN
Odstranitev	Vrstica ne sodi v analizo	Testni računi, podjetja
Omejevanje ali transformacija	Veljavno, a model je občutljiv	Minute: 99. percentil ali log
Ohranitev	Veljavna vrednost	Minute pri analizi prihodka

Možni odzivi

- Ko vemo, ali gre za napako ali ekstrem, izberemo odziv:



Shematski prikaz na umetnih podatkih.

Prikaz: kaj izgubimo, če osamelce zbrišemo?

- Telekom, minute: pravilo IQR označi **5 %** strank.
- Te stranke prinesejo **14 %** vsega prihodka.
  - Mediana prihodka: **130 USD** (ostali: 46 USD).
- Če jih zbrišemo, analiza in model **o najbolj dragocenih strankah ne vesta nič**.
- Brisanje je **odločitev**, ne samodejni korak čiščenja.

Hands-on: osamelci v spletni trgovini

- Zvezek `B_osamelci.ipynb`
- Poiščite kandidate: `vrednost`, `teza_g`, `postnina`, `dni_dostave`, `st_obrokov`.
- Poglejte najbolj ekstremna naročila in **povezane stolpce**.
- Za vsaj dva stolpca zapišite: **napaka ali ekstrem?** in **kako bi ga obravnavali?**
- Za razpravo: negativna vrednost naročila — **napaka ali vračilo?**
- **Ključno sporočilo: osamelec ni nujno napaka; včasih je ravno najzanimivejši podatek.**



Normalizacija in standardizacija

Normalizacija in standardizacija

- Numerične značilke pogosto uporabljajo različne enote in razpone.
- Skaliranje spremeni mersko lestvico, ne pomena podatkov.
- Cilj: razumeti izbiro postopka in ga pravilno uporabiti na novih podatkih.

Zakaj je merska lestvica pomembna?

- Pri razdaljah lahko prevlada značilka z večjimi številskimi razlikami.
- Že pretvorba sekund v minute spremeni njen prispevek k razdalji.
- Skaliranje uskladi lestvice; ne določi poslovne pomembnosti značilk.

Min–max skaliranje (Normalizacija)

- Odštejemo minimum in delimo z razponom.
- Najmanjša učna vrednost postane 0, največja 1.
- Postopek izvedemo ločeno za vsak numerični stolpec.
- Ekstremne vrednosti določajo meje in lahko stisnejo večino podatkov.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Minimum in maksimum ocenimo na učni množici; formula velja za nekonstanten stolpec.

Standardizacija: odmik od povprečja

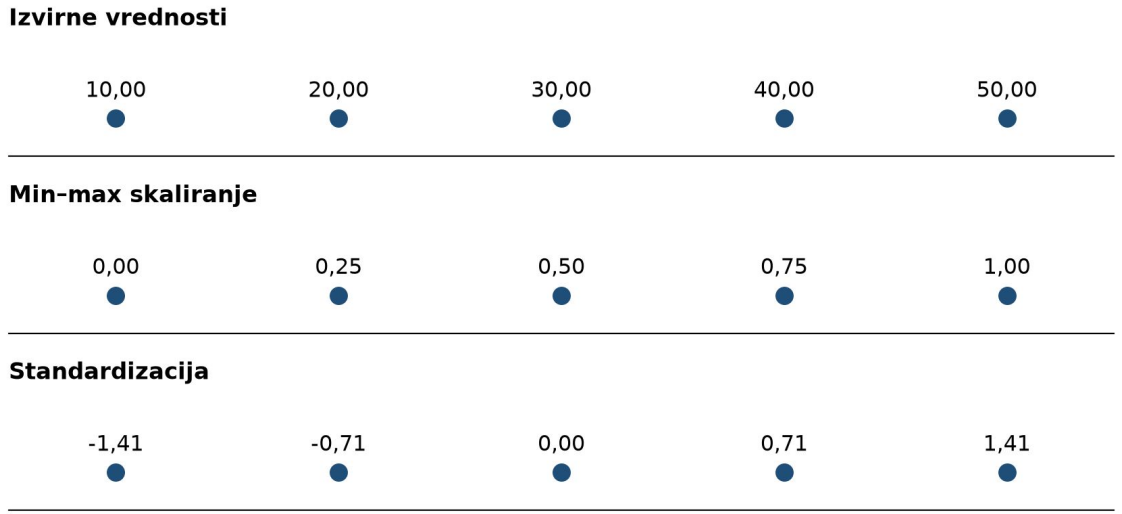
- Odštejemo povprečje in delimo s standardnim odklonom.
- Nekonstanten učni stolpec ima nato povprečje 0 in standardni odklon 1.
- z = 2 pomeni dve standardni deviaciji nad učnim povprečjem.
- Vrednosti niso omejene na [0, 1]; lahko so negativne.

$$z = \frac{x - \mu}{\sigma}$$

μ in σ ocenimo na učni množici. StandardScaler uporablja σ z deljenjem z n (ddof = 0).

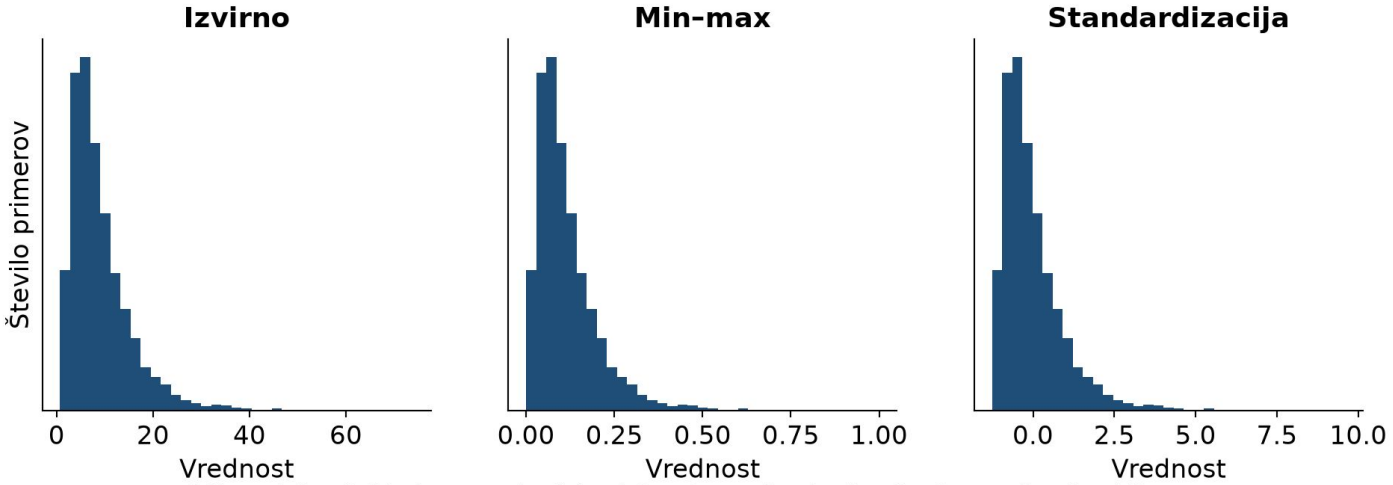
Dva postopka, različna interpretacija

- Min–max: položaj znotraj učnega razpona.
- Standardizacija: odmik od učnega povprečja v enotah standardnega odklona.
- Oba ohranita vrstni red vrednosti v nekonstantnem stolpcu.
- Nobeden ne izbriše osamelcev ali popravi podatkovnih napak.



Standardizacija ne naredi normalne porazdelitve

- Min–max in standardizacija sta linearni spremembi lestvice.
- Asimetrija, več vrhov in razmerja razdalj znotraj stolpca ostanejo.
- Logaritemska transformacija je drugačen poseg: lahko spremeni obliko porazdelitve.



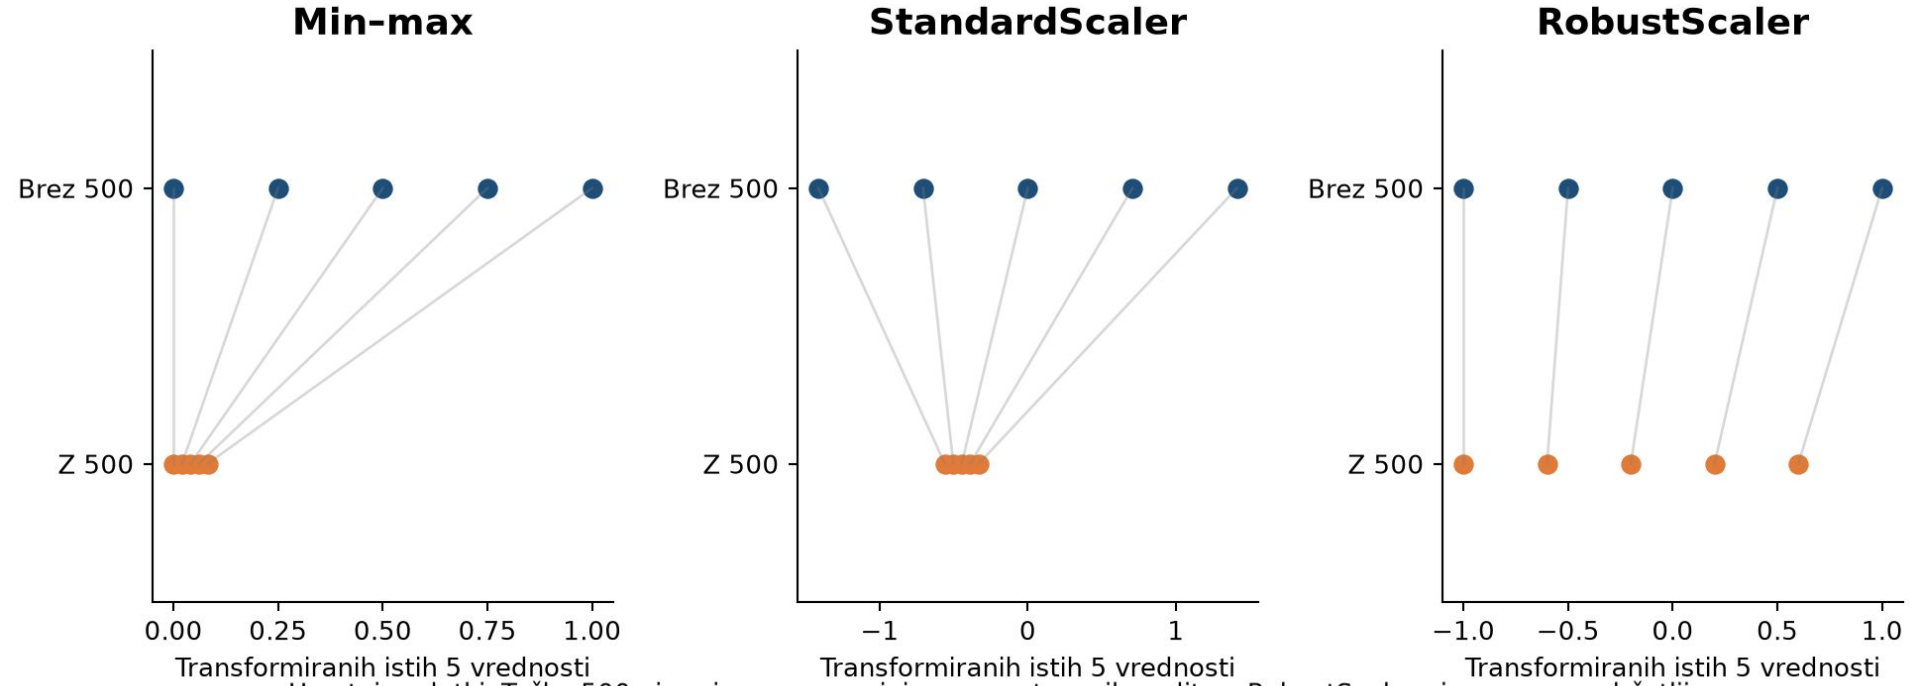
Isti umetni podatki, druge enote. Asimetrija ostane; standardizacija ni normalizacija oblike.

Kadar so prisotni ekstremi: RobustScaler

- Centriranje z mediano, skaliranje z interkvartilnim razmikom.
- Parametri so praviloma manj občutljivi na posamezne ekstreme.
- Ekstrem ostane ekstrem; rezultat ni omejen na določen interval.
- Ne nadomešča pregleda kakovosti podatkov.

$$x' = \frac{x - \text{mediana}(x)}{Q_3 - Q_1}$$

Privzeti RobustScaler: odštejemo mediano in delimo z IQR; ekstremnih vrednosti ne odstrani.



Umetni podatki. Točka 500 ni narisana; spreminja parametre prilagoditve. RobustScaler ni povsem neobčutljiv.

Kdaj skaliramo?

- Pomembno: K-means, k-NN, PCA ter številni regularizirani linearni modeli in SVM.
- Običajno ni potrebno: odločitvena drevesa, naključni gozdovi, …
- StandardScaler je smiselno začetno izhodišče; izbiro preverimo z validacijo.
- ID-jev in kategorijskih kod ne skaliramo kot merjene količine.

Fit na učnih, transform tudi na novih podatkih

- fit: iz učnih podatkov izračunamo in shranimo parametre.
- transform: uporabimo iste shranjene parametre.
- Testne in nove množice ne prilagajamo z novim fit.
- Nove min–max vrednosti lahko padejo izven [0, 1].

Učenje (fit)	**Novi podatki (transform)**
10, 20, 30, 40, 50	$60 \rightarrow (60 - 10) / 40 = 1{,}25$

Shranimo: min = 10, max = 50. Na novih podatkih NE računamo novih mej.

Vaja



Kaj si zapomnimo?

- Skaliranje prilagodi merske lestvice; ni čiščenje podatkov.
- Min–max uporablja minimum in maksimum; standardizacija povprečje in odklon.
- RobustScaler uporablja mediano in IQR.
- Standardizacija ne pomeni normalne porazdelitve.
- Parametre vedno naučimo samo na učnih podatkih.



Oblikovanje značilk

Uvod

- Iz podatkov oblikujemo informacije, ki jih model lahko uporabi.
- Izbira značilk temelji na poslovnem vprašanju in razpoložljivih podatkih.
- Dobra značilka mora biti smiselna, ponovljiva in dostopna ob napovedi.

Najprej določimo, kaj predstavlja vrstica

- Ena vrstica lahko predstavlja postavko, naročilo ali kupca.
- Raven značilk mora ustrezati ravni napovedi.
- Dve postavki istega naročila ne pomenita dveh nakupov.
- Za združevanje potrebujemo pravilen identifikator.



Od surovih vrednosti do uporabne značilke

- Agregacije: koliko, skupaj, povprečno, največ.
- Razmerja: vrednost glede na obseg ali preteklo raven.
- Časovne značilke: kdaj in koliko časa od dogodka.
- Kazalniki: ali se je dogodek zgodil.
- Kodiranje kategorij: kako pomen predstavimo modelu.

Agregacije: zgodovino povzamemo v vrstico

- Skupino določimo z identifikatorjem, npr. ID kupca.
- Obdobje določa, kateri dogodki štejejo.
- COUNT, SUM, MEAN in MAX odgovarjajo na različna vprašanja.
- Število vrstic ni vedno število dogodkov: pogosto potrebujemo nunique.

Naročilo	Vrednost
N1	20 €
N2	30 €
N3	50 €



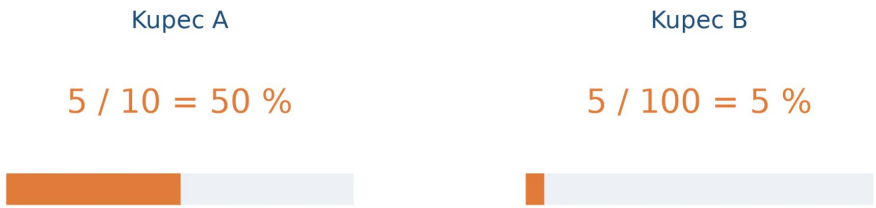
Značilka	Vrednost
Število	3
Vsota	100 €
Povprečje	33,33 €

Pazimo na podvajanje pri združevanju

- Več postavk in več plačil istega naročila povzroči množenje vrstic.
- Seštevanje po takem združevanju lahko napihne vrednosti.
- Vsako tabelo najprej agregiramo na želeno raven.
- Preverimo ključe, število vrstic in skupne zneske.

Razmerja potrebujejo smiseln imenovalec

- Enako število dogodkov lahko pomeni različen delež.
- Razmerje omogoča primerjavo ob različnem obsegu aktivnosti.
- Pri imenovalcu 0 je razmerje praviloma nedoločeno, ne enako 0.
- Preverimo enote in časovno obdobje obeh količin.

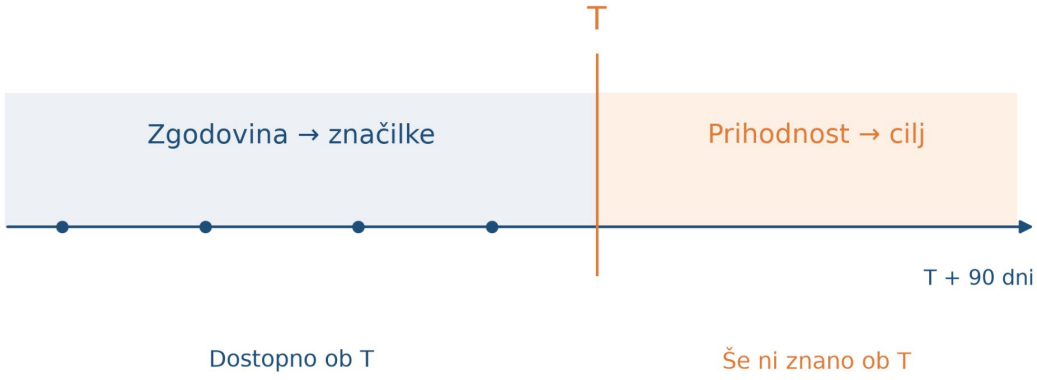


Časovne značilke: trenutek določa pomen

- Iz datuma izluščimo dan v tednu, uro ali mesec.
- Iz dveh časov izračunamo pretečeni čas.
- Zgodovino omejimo na določeno okno, npr. zadnjih 180 dni.
- Danes ni primeren premični referenčni datum za zgodovinski učni primer.
- Zelo pomembno, ko zaznamo časovne trende v podatkih.

Prihodnosti ne smemo skriti v značilke

- Določimo trenutek napovedi T.
- Uporabimo samo podatke, ki so bili takrat že dostopni.
- Značilke iz zgodovine in prihodnji izid sta časovno ločena.
- Datum dostave ni znan ob oddaji naročila.



Primer domenskih značilk: RFM

- Recency: koliko dni je od zadnjega nakupa do T.
- Frequency: koliko različnih naročil je v opazovanem oknu.
- Monetary: skupna vrednost naročil v istem oknu.
- Vnaprej določimo, kaj šteje kot nakup in kaj vključuje vrednost.



R	F	M
10 dni	3 naročila	20 + 30 + 50 = 100 €

Kodiranje kategorij ohranja njihov pomen

- Nominalne kategorije nimajo naravnega vrstnega reda.
- One-hot: posamezna kategorija dobi svoj kazalnik 0/1.
- Ordinalno kodiranje uporabimo le za dejansko urejene kategorije.
- Vrstni red še ne pomeni enakih razdalj med kategorijami.

Brez vrstnega reda

Plačilo	Kartica	Gotovina	Bon
Kartica	1	0	0
Gotovina	0	1	0
Bon	0	0	1

One-hot

Z vrstnim redom

Raven	Koda
Nizka	0
Srednja	1
Visoka	2

$0 < 1 < 2$

Nove kategorije in ponovljiva priprava

- Slovar kategorij določimo na učni množici.
- Nove podatke pretvorimo po istem pravilu in v iste stolpce.
- Vnaprej določimo ravnanje z neznano kategorijo.
- Korake priprave shranimo skupaj z modelom.

Vaja



Kontrolni seznam pred učenjem modela

- Ena vrstica na izbrano opazovanje; identifikatorji so enolični.
- Ni neskončnih vrednosti; manjkajoče so označene in razumljene.
- Cilj in ID sta ločena od vhodnih značilk.
- Značilke so dostopne v trenutku napovedi.
- Izračun lahko ponovimo na novih podatkih.